



UNIVERSIDAD NACIONAL DE SAN JUAN  
FACULTAD DE INGENIERÍA

TRABAJO FINAL DE GRADUACIÓN

**Una estrategia para la clasificación  
óptica de almendras**

Pablo Daniel AGUADO

ASEORES:

Dr. Ing. Humberto SECCHI

Dr. Ing. Adrián ORELLANA

Dr. Ing. Francisco ROSSOMANDO

Mg. Ing. Eduardo ZAVALLA

Agosto de 2017

En este trabajo se diseñó y desarrolló un programa informático para la clasificación automática de almendras peladas mediante procesamiento de imágenes, analizando diversas características de forma y de color. Para ensayar lo construyó un prototipo de sistema de visión artificial con el cual se creó un conjunto de 564 imágenes de almendras y otros objetos. El conjunto de imágenes fue etiquetado manualmente en base a las normas de la Comisión Económica de las Naciones Unidas para Europa (UNECE) para el comercio de almendras. Los resultados del clasificador desarrollado son similares a los obtenidos con algoritmos de clasificación estándar, como máquinas de soporte vectorial o *Boosted Trees*. Los descriptores elegidos permiten clasificar binariamente el conjunto con una exactitud global de 93 %.

## **Agradezco a todos, por todo.**

*Dicho eso, expando mis agradecimientos a quienes de alguna u otra manera contribuyeron a este Trabajo Final y a todos los años de estudio que le preceden. Espero que esto todavía tenga sentido para mí cuando lo relea en unos años.*

*Gracias*

- *a mis asesores: Humberto, Adrián, Francisco y Eduardo. Mención especial para Humberto por su empuje y para Adrián por las discusiones técnicas.*
- *a los habitantes permanentes y temporales del Laboratorio de Sistemas Sensoriales del INAUT, con quienes compartí estos últimos meses. Daniel, Diego, Adrián, Francisco, Checa, Carlos, Pepe, Vera, ...*
- *a quienes comparten gratuitamente sus creaciones y su experiencia; y a todos los que contribuyeron a las herramientas abiertas que usé en este trabajo: LaTeX, TeXstudio, KNIME, YAMLMatlab, Git, PlantUML, GIMP, G'MIC, Inkscape, Atom, Notepad++, Wikimedia, ...*
- *a mis profesores todos. Soy, en parte, fruto de su esfuerzo. Espero que siempre sean conscientes de la responsabilidad que tienen, y que el mundo se las reconozca.*
- *a la UNSJ toda: autoridades, personal docente y no docente, alumnos, egresados e invitados. Agradezco especialmente a todas las personas que durante estos años me han apoyado en cada una de mis iniciativas. Un abrazo para todos aquellos que trabajan con dedicación en una verdadera búsqueda del progreso.*
- *a la Facultad de Ingeniería y sus dependencias. Me llevo mucho de aquí, y también aquí he dejado bastante. Espero seguir viniendo un tiempo más.*
- *al GERUNSJ, espacio en el cual pude crear muchas cosas y aprender aún más, de la ciencia, de la ingeniería y de las personas. Gracias a quienes lo hicieron, a quienes lo hacen y a quienes lo dejan hacer. No mueras, GERUNSJ.*
- *a mi familia toda, por estar siempre presentes. Primos, tíos, abuelos, otros y los que vengan. Espero que nos juntemos a ver el mundial en 2018. ¿Podrá la Pulga al fin alzar la copa?*
- *a mi familia cercana, que me impulsó e impulsa a vivir. Agradecimientos especiales a mi mamá Lila por conseguirnos comida y por insistir en que terminara con esto de una buena vez; a mi papá Daniel y a mi hermano Francisco por mantener el taller en condiciones; a mi hermano Leonardo por los intercambios de ideas; y a mi hermano Agustín por levantar la mesa de vez en cuando y dejarme trabajar tranquilo.*
- *a mis compañeros de la UNSJ con quienes compartí muchas risas, horas y conocimiento. En especial a esos ilusos con quienes forjé amistad en los primeros años. «Este semestre voy a ir al día», se oía por los pasillos.*
- *a mis amigos, compañeros de ruta. Quienes son, quienes lo hayan sido. Quienes hayan venido a mi casa, o a cuya casa yo haya ido, o quienes hayan vivido conmigo lejos de nuestras casas. Quienes me impulsaron o ayudaron a aportar algo al mundo. Quienes hayan reído o llorado conmigo. Quienes hayan intentado a mi lado entender de qué se trata todo esto, qué hay más allá de las estrellas y el por qué de las emociones más bellas.*
- *a los inconformes que se preguntan por qué.*
- *a quienes encienden llamas de curiosidad, inyectan dosis de confianza y provocan hambre de cambio. Porque la motivación lo es todo.*
- *a vos, por leer.*

*Pablo*

# Índice general

<b>1</b>	<b>Prefacio</b>	<b>1</b>
<b>2</b>	<b>Introducción</b>	<b>2</b>
2.1	Problemática y motivación . . . . .	2
2.2	La almendra . . . . .	3
2.3	Normas . . . . .	4
2.4	Soluciones existentes . . . . .	4
2.5	Propuesta . . . . .	6
2.6	Herramientas y materiales . . . . .	7
<b>3</b>	<b>Captura de imágenes</b>	<b>8</b>
3.1	Condiciones . . . . .	8
3.1.1	Muestra disponible . . . . .	8
3.1.2	Conjunto de imágenes . . . . .	9
3.1.3	Sistemas de movimiento, captura y rechazo . . . . .	9
3.1.4	Modelo . . . . .	10
3.2	Prototipo . . . . .	10
3.3	Cámara . . . . .	11
3.3.1	Calibración de la cámara . . . . .	13
3.4	Pruebas de sistemas de visión . . . . .	14
3.4.1	Vidrio y espejos . . . . .	14
3.4.2	Fondo blanco . . . . .	15
3.4.3	Retroiluminación . . . . .	16
3.5	Conjunto de imágenes . . . . .	17
3.5.1	Condiciones de adquisición . . . . .	18
3.5.2	Procedimiento de adquisición . . . . .	18
3.5.3	Características de las imágenes . . . . .	18
3.5.4	Clasificación . . . . .	20
3.6	Partición y preprocesado . . . . .	24
<b>4</b>	<b>Estrategia de clasificación</b>	<b>26</b>
4.1	Esquema general e implementación . . . . .	26
4.1.1	Preprocesamiento . . . . .	28
4.1.2	Segmentación . . . . .	28
4.1.3	Clasificación . . . . .	29
4.2	Etapas de segmentación . . . . .	29
4.2.1	Definiciones . . . . .	29
4.2.2	Detección de bordes sobre fondo blanco . . . . .	31
4.2.3	Retroiluminación + umbral en gris . . . . .	33
4.2.4	Umbralización del tono . . . . .	35

4.3	Etapas clasificadoras . . . . .	37
4.3.1	Definiciones . . . . .	37
4.3.2	Descriptor 1: altura de caja envolvente . . . . .	40
4.3.3	Descriptor 2: proporción de arrugas . . . . .	42
4.3.4	Descriptor 3: relación de aspecto de caja envolvente . . . . .	44
4.3.5	Descriptor 4: media de color en CIEL*a*b* — componente a* . . . . .	46
4.3.6	Descriptor 5: media de color en CIEL*a*b* — componente b* . . . . .	47
4.3.7	Descriptor 6: relación de aspecto de elipse ajustada . . . . .	47
4.3.8	Descriptor 7: extensión de caja envolvente . . . . .	48
4.3.9	Descriptor 8: desviación estándar del color según el matiz . . . . .	50
4.3.10	Descriptor 9: media del color según el matiz . . . . .	51
4.3.11	Descriptor 10: área sin tegumento según canal S . . . . .	52
4.3.12	Descriptor 11: área sin tegumento según canales H, S y V . . . . .	54
4.3.13	Descriptor 12: solidez . . . . .	56
<b>5</b>	<b>Resultados</b>	<b>58</b>
5.1	Metodología de ajuste y evaluación . . . . .	60
5.1.1	Evaluación . . . . .	60
5.1.2	Métrica . . . . .	61
5.1.3	Ajuste . . . . .	61
5.2	Resultados . . . . .	62
<b>6</b>	<b>Conclusiones</b>	<b>65</b>
6.1	Revisión . . . . .	65
6.2	Discusión y trabajos futuros posibles . . . . .	66
6.2.1	Sistema de visión . . . . .	66
6.2.2	Conjuntos de imágenes . . . . .	66
6.2.3	Evaluación . . . . .	66
6.2.4	Descriptores . . . . .	66
6.2.5	Clasificador . . . . .	67
<b>Referencias</b>		<b>68</b>
Programas . . . . .		69
Créditos de imágenes . . . . .		69
<b>A Organización de los archivos</b>		<b>71</b>
<b>B Uso de los programas</b>		<b>72</b>

*Dedico este trabajo a quien le sea útil.*

*En El Principito de Antoine de Saint-Exupéry, el protagonista encuentra a un hombre de negocios que acumula estrellas con el único propósito de poder comprar más estrellas.*

*El Principito está perplejo. Solo posee una flor, que riega a diario, y tres volcanes que limpia cada semana.*

*«Es útil, pues, para mis volcanes y para mi flor que yo las posea», dijo el Principito, «pero tú, tú no eres nada útil para las estrellas. . . ».*

<http://custodians.online/spanish3.html>

## 1 Prefacio

Este documento es el informe del Trabajo Final que llevé a cabo en cumplimiento parcial de los requerimientos establecidos para obtener el título de Ingeniero Electrónico en la Universidad Nacional de San Juan. Da cuenta de las actividades que se realizaron para este trabajo durante los meses de noviembre y diciembre de 2016; y desde abril hasta agosto de 2017.

Está dirigido a mis asesores, a alumnos de Ingeniería Electrónica y a la academia en general. Podrán sacar mayor provecho de él aquellos alumnos que hayan cursado las materias Temas específicos de Control I (Sistemas de Visión por Computadora) y Complementos de Inteligencia Artificial, o tengan experiencia en procesamiento de imágenes, sistemas de visión, clasificación automática y aprendizaje supervisado.

En el primer capítulo («Introducción») se presenta la problemática que originó este trabajo, se comentan generalidades de la temática y se presenta la propuesta de trabajo junto a las herramientas utilizadas. En el segundo capítulo («Captura de imágenes») se mencionan los prototipos de sistemas de visión construidos y el conjunto de imágenes generado. Posteriormente, en el tercer capítulo («Estrategia de clasificación»), se detalla el programa clasificador creado y los descriptores elegidos para caracterizar las imágenes. En el capítulo «Resultados» se presenta la forma en que se evaluó la solución propuesta, y se contrastan los resultados con los de otros sistemas de clasificación. Por último, en «Conclusiones», se revisa y critica todo lo realizado, y se proponen cuestiones a tener en cuenta para continuar el desarrollo de una buena máquina clasificadora.

Acompañan al informe archivos digitales correspondientes a los programas desarrollados y a los conjuntos de imágenes generados.<sup>1</sup> Los anexos A y B describen la organización de estos archivos y la forma de usar los programas, respectivamente.

Pablo Daniel AGUADO  
DNI 35 506 690  
Registro 23724  
aguadopd@hotmail.com

---

<sup>1</sup>Las imágenes se encuentran disponibles en [1].

## 2 Introducción

### 2.1 Problemática y motivación

La almendra es la fruta seca de mayor producción y consumo en el mundo. [2] Se comercializa con diversos grados de industrialización: con cáscara; pelada; blanqueada; en trozos; como harina; como aceite y como pasta, entre otros. El mercado mundial de las almendras está dominado en un 80 % por dos principales productores: Estados Unidos y España. En 2015, nuestro país tenía más de 4000 hectáreas cultivadas (ver tabla 2.1), siendo Mendoza la provincia de mayor superficie cultivada, seguida por San Juan y La Rioja. En 2013 se importaron más de 1800 toneladas de almendras para el consumo local —desde Chile y Estados Unidos—, mientras que se exportaron 33 toneladas a España, Paraguay y Uruguay. [3]

**Tabla 2.1:** cultivos de almendra en Argentina en 2015. [4]

Provincia	Superficie cultivada [Ha]
Mendoza	2580
San Juan	572
La Rioja	498
Salta	189
Río Negro y Neuquén	170
Otras	200
Total	4209

El procesamiento mínimo para comercializar las almendras implica el descapotado y el pelado. El descapotado consiste en eliminar la cáscara externa o «capote» (exocarpio y mesocarpio del fruto); en el pelado se rompe la cáscara interna (endocarpio del fruto) para finalmente extraer la semilla. Este procesamiento es realizado mecánicamente por máquinas especializadas, pero puede provocar ligeros daños en algunos frutos. Posteriormente se realiza un proceso de clasificación o filtrado en el cual se eliminan restos de cáscaras, almendras dañadas y cualquier objeto extraño. Esta clasificación es habitualmente realizada mediante clasificadores ópticos, máquinas de alta tecnología y costo que mediante iluminadores, cámaras y eyectores de aire, separan los productos buenos de los malos y la basura.

En la región, y particularmente en la provincia de San Juan, la producción está centrada en pequeñas y medianas empresas agroindustriales. Hoy en día algunos productores optan por vender las almendras con cáscara; serán otros quienes les den, al pelarlas, mayor valor agregado. Otros productores sí realizan esa etapa de procesado, separando las almendras buenas de forma manual, lo cual requiere mano de obra especializada y muchas horas de trabajo; el promedio por operario es de entre 15 y 30 kg por jornada. La escasez de mano de obra especializada (debido a lo rutinario de la tarea) impacta en los

costos de producción, pero estos productores no pueden afrontar los costos de adquirir una máquina clasificadora óptica.

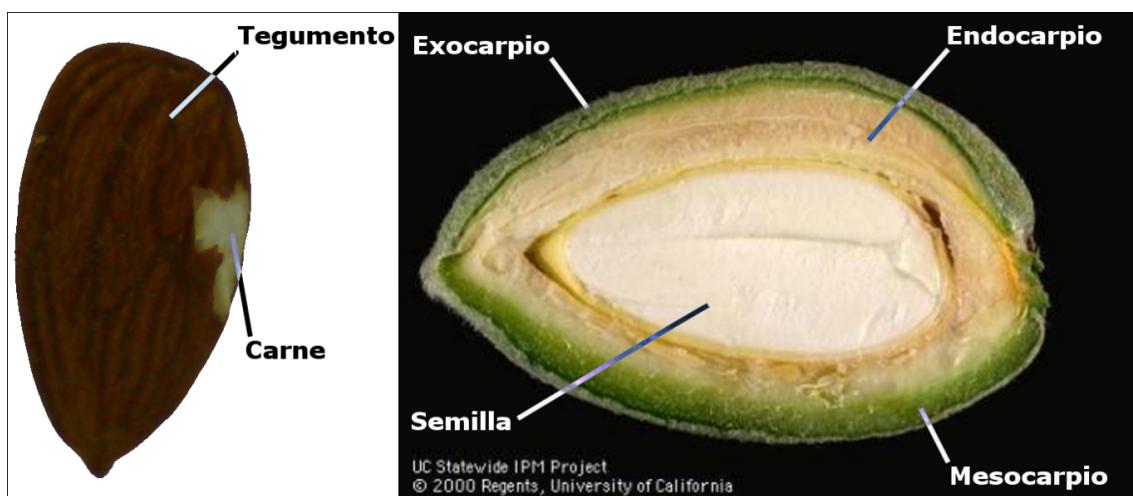
El Proyecto de Desarrollo Tecnológico y Social (PDTs) «Diseño e implementación de una estrategia de clasificación óptica de almendras para pequeños productores» es una iniciativa impulsada por la Universidad Nacional de San Juan (UNsj) y la Secretaría de Ciencia, Tecnología e Innovación del Gobierno de San Juan (SECITI) que pretende, a largo plazo, desarrollar una clasificadora óptica de almendras destinada al sector MiPyME agroindustrial de la región del Nuevo Cuyo. [5] Para ello hay que diseñar, construir y probar todas las partes mecánicas, electrónicas y de software de la máquina, como así también los procesos que en ella se realizan y cómo se integran a los procesos existentes. Debe ser de bajo costo y ser al menos tan eficiente como un operario humano que clasifica manualmente.

Este trabajo es un pequeño aporte inicial a ese PDTs, y aborda el diseño e implementación de un sistema de visión artificial para la clasificación de almendras

## 2.2 La almendra

La almendra es el fruto (tipo drupa) del árbol llamado almendro (*Prunus dulcis* [Mill.] D.A. Webb). Una drupa es un fruto monospermo de mesocarpio carnoso, coriáceo o fibroso, que rodea a un endocarpio leñoso (carozo o hueso) con una sola semilla en su interior. Otras drupas son el durazno, la cereza, la aceituna y el café.

En la almendra el mesocarpio y el exocarpio forman la parte más blanda, correosa, del fruto; se conoce como cáscara o capote (en inglés: *hull*). El endocarpio (ver figura 2.1) es la cáscara dura, carozo o hueso (en inglés: *shell*). En la parte interna del carozo está la semilla (*kernel*) dicotiledónea, que es lo que vulgarmente se conoce como almendra. Esta se puede dividir longitudinalmente en dos mitades llamadas cotiledones. La semilla tiene una piel marrón que la rodea: el tegumento. Para diferenciar las partes de la semilla, llamaremos «carne» a la parte blanca que está dentro del tegumento.



**Figura 2.1:** partes de una almendra. Izquierda: semilla; derecha: corte de un fruto completo. [6]

## 2.3 Normas

Existen normas que regulan el comercio de almendras peladas (sin cáscara). Hay tres normas que fueron útiles para definir los defectos a encontrar:

1. la Resolución 1352/1967 (capítulos XV y XIX) de la antigua Secretaría de Agricultura y Ganadería de la República Argentina, hoy bajo la órbita del Servicio Nacional de Sanidad y Calidad Agroalimentaria (SENASA); [7]
2. el «Estándar estadounidense para la calidad de almendras peladas», elaborado por el Departamento de Agricultura de ese país (USDA); [8]
3. el «Estándar DDP-06 acerca de la comercialización y control de calidad comercial de semillas de almendra», elaborado por la Comisión Económica de las Naciones Unidas para Europa (UNECE). [9]

Los tres documentos definen rasgos generales sobre los bienes a comercializar, y caracterizan defectos a encontrar, como «almendras partidas», «almendras dobles», «moho», «fragmento» y otros. Por último, establecen clases de calidad, cada una con distinta tolerancia a defectos o variaciones.

Las normas de UNECE y USDA son más explícitas a la hora de definir los defectos que la norma de SENASA. El Código Alimentario Argentino replica en su capítulo XI una versión abreviada de la Resolución 1352/1967. [10]

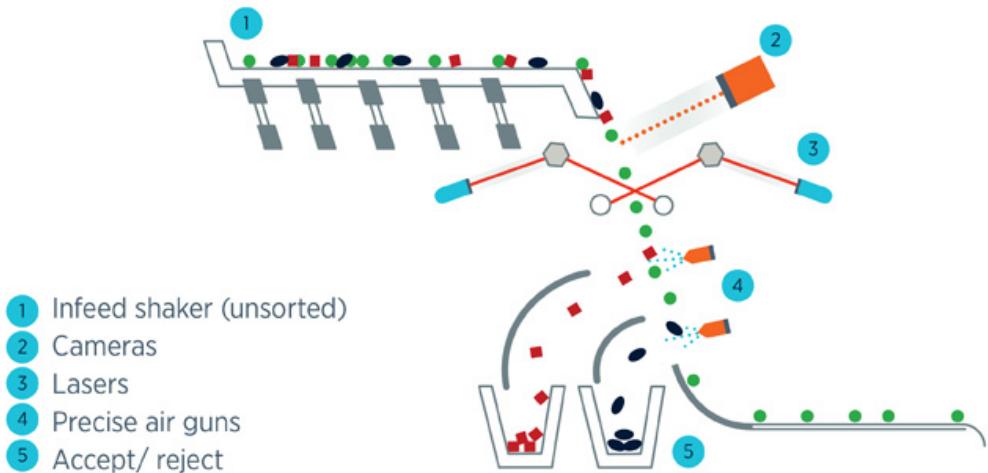
## 2.4 Soluciones existentes

Existen en el mercado máquinas capaces de resolver el problema con el mismo enfoque; se denominan máquinas de clasificación óptica o seleccionadoras ópticas (en inglés es común denominarlas como *optical sorting machines*, y no *optical classification machines*). Se utilizan, en general, luego de etapas de filtrado mecánico. Estas máquinas pueden usarse para una gran cantidad de frutos; el fabricante ajusta sus parámetros y añade o quita componentes según el fruto a clasificar y el presupuesto del comprador.

La estructura de la gran mayoría de ellas consiste de:

1. Una cinta transportadora o plataforma vibradora, que mueve los frutos.
2. Un tobogán o tubo que guía los frutos hacia un espacio de caída libre.
3. Una o más cámaras que capturan imágenes desde uno o ambos lados del objeto.
4. Eyectores que soplan los objetos malos.
5. Salidas de objetos malos y objetos buenos.

A modo de ejemplo, la figura 2.2 muestra un esquema de funcionamiento de una clasificadora Tomra Nimbus.



**Figura 2.2:** diagrama de funcionamiento de una máquina Tomra Nimbus. [11]

La figura 2.3 muestra la salida típica de una máquina clasificadora. Los defectos que pueden detectarse están determinados por el software de las máquinas y por el sistema de visión que tienen. Respecto a esto último, pueden tener cámaras e iluminadores en el espectro visible, en ultravioleta y en infrarrojo, que permiten detectar:

- Problemas de forma;
- Problemas de color;
- Hongos y toxinas superficiales;
- Objetos extraños.



**Figura 2.3:** salida de una máquina clasificadora comercial. De izquierda a derecha: almendras aceptadas; rechazadas por astilladas o raspadas; rechazadas por tamaño; rechazadas por ser cáscaras, almendras manchadas o podridas. [12]

La mayoría usa sensores CCD e iluminadores led, pero algunas incorporan luz láser y los sensores correspondientes, para analizar ciertos defectos.

Algunas empresas que fabrican estas máquinas son Tomra, Bühler, Cimbria y Key Technology; algunas de sus máquinas se muestran en la figura 2.4. Hay muchas más que fabrican máquinas simples que solo analizan el color. No se encontró información respecto a la precisión de las máquinas. Su capacidad depende del producto a analizar y los defectos a encontrar, pero es mayor a 0,5 toneladas/hora, pudiendo alcanzar 15 toneladas/hora.

En nuestro país, las máquinas de la familia Sortex de Bühler tienen un costo que oscila entre los 100 000 USD y los 300 000 USD —alrededor de 1 780 000 ARS y 5 340 000 ARS respectivamente, en agosto de 2017—, dependiendo de los defectos a remover y la capacidad de producción (entre 2 y 15 toneladas/hora). En función de esto varían el tipo y cantidad de cámaras (entre dos y veinte).<sup>1</sup>



**Figura 2.4:** máquinas clasificadoras ópticas. De izquierda a derecha: Bühler Sortex A, Bühler Sortex E, Tomra Nimbus. [13, 14]

## 2.5 Propuesta

En este trabajo se quisieron abordar tres áreas específicas de la máquina: el software de clasificación, el proceso de captura y el sistema de desplazamiento de las almendras. Una vez comenzado el trabajo se hizo evidente que el sistema de visión artificial necesario no es independiente de los mecanismos de traslación y eyección de objetos. Dado que estos últimos no están definidos todavía (y dependen de otras partes del proceso), adoptar un subsistema de visión único, sin considerar posibles limitaciones a las otras partes del sistema clasificador, es una decisión que probablemente implicaría problemas en futuras etapas. Es por esto que se decidió:

1. Hacer pruebas cortas de posibles sistemas de visión, lo más genéricos posibles.
2. Tomar el que mejor funcione (según algún criterio) y utilizarlo para generar un gran conjunto de imágenes.

Este conjunto de imágenes se usa para evaluar la efectividad que tienen diversos descriptores o predictores para clasificar los objetos que ingresen al sistema. Algunos de los descriptores usados son propuestos en la literatura revisada, mientras que otros surgen de nuestro análisis del problema de clasificación. Análogamente, se prueban diversas formas de identificar de forma única las posiciones y límites de los objetos en las imágenes —tarea conocida como segmentación—.

El conjunto de imágenes fue generado a partir de almendras y otros objetos provistos por un productor local. Se utilizaron (parcialmente) las normas de UNECE como verdad o patrón de referencia, para definir los defectos a buscar en las almendras y para comparar los resultados obtenidos. Algunos valores de referencia, como el color y el tamaño, se determinan a partir de la muestra ya que son características que varían naturalmente entre especies y cosechas.

<sup>1</sup>Según comunicación por correo electrónico con Walter Tosco de Bühler Sortex Argentina (<http://sortex.com.ar>).

## 2.6 Herramientas y materiales

Se resumen a continuación algunas de las herramientas y materiales que se utilizaron en este trabajo. Se extenderá su descripción y forma de uso en secciones posteriores.

1. Cámara web Genius eFace 2050AF.
2. Muestras de almendras y otros objetos, provistos por el productor.
3. Matlab R2015b [15]. Se decidió hacer el desarrollo de los algoritmos en Matlab, ya que es una herramienta versátil; buena para la experimentación y el análisis; y de amplio uso en el Instituto de Automática (INAUT), donde probablemente se continúe el desarrollo del sistema.

Cajas de herramientas usadas:

- a) Image Processing Toolbox
- b) Computer Vision System Toolbox
- c) Image Acquisition Toolbox
- d) Statistics and Machine Learning Toolbox

Otros:

- a) Matlab Support Package for USB Webcams
- b) YAMLMatlab, para trabajar con archivos YAML de configuración de parámetros [16]
- c) MBeautifier, para uniformar el formato del código [17]
- d) multic (Confusion Matrix and its Derivations) [18]
- e) Balu Toolbox for Matlab [19]
4. GIMP 2.8.18: Programa de edición de imágenes utilizado como complemento a Matlab para el diseño de algoritmos y análisis de las imágenes disponibles. Se usó también el complemento G'MIC 1.79 para el procesamiento. [20, 21]
5. KNIME 3.3.2: Programa de minería de datos usado para comparar resultados. [22]
6. Perfiles metálicos y accesorios; poliestireno de alto impacto; madera MDF; vidrios y espejos, para la construcción de un prototipo de estructura.
7. Tiras de leds, una fuente conmutada y materiales eléctricos, para la construcción de luminarias.

## 3 Captura de imágenes

### 3.1 Condiciones

En esta sección se mencionan las condiciones existentes o autoimpuestas que limitaron y orientaron el proceso de la captura de imágenes y el diseño de la estrategia de clasificación.

#### 3.1.1 Muestra disponible

Para la construcción de este conjunto se contó con dos grupos de objetos aportados por un productor local. El primer grupo consiste en una muestra representativa de lo obtenido luego de la clasificación manual. El segundo incluye algunas almendras buenas, pero consiste principalmente en almendras que son consideradas malas y objetos que no son almendras pero que típicamente se encuentran en las etapas de procesamiento.



**Figura 3.1:** objetos del grupo 1 (muestra).



**Figura 3.2:** objetos del grupo 2 (muestra).

### 3.1.2 Conjunto de imágenes

Los algoritmos deben probarse sobre un conjunto de imágenes que debe:

1. Ser suficientemente grande y diverso, para describir el problema de la forma más completa posible.
2. Tener poco ruido. Esto implica que no debe incluir cosas que no se quieren modelar porque no son parte del problema.
3. Estar bien etiquetado o clasificado. Las etiquetas o clases son aquellas palabras arbitrariamente elegidas para describir un conjunto de objetos que comparten atributos.
4. Poder ser reutilizado y compartido fácilmente.

### 3.1.3 Sistemas de movimiento, captura y rechazo

Las condiciones en las que se toman las imágenes están sujetas al sistema de visión, y este depende de las propiedades de la estructura de la máquina y los mecanismos de movimiento y eyeción o rechazo. Respecto a todo esto, se discutieron varias alternativas para cada etapa; algunas se listan a continuación:

#### Traslación

1. Cinta transportadora.
2. Plataforma vibratoria.
3. Molino.

#### Anverso/reverso

1. El objeto se sitúa sobre un vidrio transparente.
2. Hay cámaras a ambos lados, desfasadas o no.
3. El objeto se sitúa sobre un vidrio transparente. Se usa un arreglo de espejos y una sola cámara.
4. Se captura el anverso, el objeto se rota mecánicamente ( $180^\circ$  sobre el eje longitudinal, para una almendra en buen estado) y en forma subsiguiente se captura el reverso, por la misma cámara u otra.
5. Se captura un solo lado y se supone que el otro es igual.
6. Se captura un solo lado y el objeto se reingresa varias veces al sistema. Se debe proveer de un mecanismo que posibilite la rotación (aleatoria) del objeto.
7. El objeto se desplaza un tramo en caída libre, en el cual se capturan anverso y reverso en forma simultánea o no.

## Captura

1. Una cámara.
2. Dos cámaras, del mismo lado del objeto.
3. Una cámara y un arreglo de espejos.
4. Dos cámaras, una de cada lado del objeto.

## Rechazo

1. Con aire comprimido.
2. Con paletas giratorias montadas sobre el recorrido.
3. Con actuadores lineales montados a los lados del recorrido.

### 3.1.4 Modelo

Contemplando la variedad de posibles métodos de movimiento, captura y eyección, se proponen a continuación algunas características establecidas para el universo modelado; estas podrían abarcar a la mayoría de aquellos métodos, y determinaron una base concreta para la generación del conjunto de imágenes y el dispositivo de visión.

1. Hay almendras buenas y con defectos.
2. Hay objetos que no son almendras pero que pueden llegar al clasificador.
3. Se capturan imágenes del anverso y el reverso de cada objeto.
4. Hay solo un objeto por imagen.
5. La iluminación es uniforme espacial y temporalmente.
6. Los objetos están estáticos.
7. El fondo es uniforme y contrasta con la mayoría de los objetos.
8. La cámara y sus parámetros variables se mantienen fijos.

## 3.2 Prototipo

En base a lo anterior, diseñé y construí una plataforma de prototipado (ver figura 3.3) que pretendió ser versátil, flexible, con la capacidad de soportar distintas estrategias de captura de imágenes y con espacio suficiente para, eventualmente, probar los sistemas de movimiento y rechazo de objetos. La estructura externa es un prisma de base cuadrada sin su base inferior. Dentro de ella hay estantes o pisos de altura ajustable, que pueden soportar luminarias, espejos, vidrios, cámaras o muestras, por

nombrar algunos ejemplos. Todo está construido con perfiles L metálicos (perfiles ángulo), que tienen orificios rectangulares a lo largo de sus caras; estos permiten elegir las alturas de cada estante. La unión entre las piezas se realiza con tuercas y tornillos. Se usaron también escuadras metálicas que garantizan la ortogonalidad de las uniones.



**Figura 3.3:** vistas del prototipo construido, con y sin tapas.

Se construyeron tapas o paredes laterales de madera MDF de 3 mm con terminación en melamina blanca con reflexión levemente difusa. Las tapas dan mayor iluminación a los espacios interiores. Se acoplan a la estructura usando imanes. La misma madera es la base de las luminarias. Estas son cuadros planos con tiras de leds tipo SMD5050 de color blanco frío y una densidad de 60 leds/metro. Hay dos luminarias: una inferior y otra superior. En el centro tienen un agujero cuadrado en el donde se pueden colocar cámaras o espejos, por ejemplo. Los leds están dispuestos formando cuadros concéntricos con el agujero central (ver figura 3.4).

El prototipo tiene una fuente de 12 V y 10 A que alimenta los leds. Cuenta con una llave de encendido general y dos llaves que controlan las luminarias inferior y superior respectivamente. Se usaron cuadros planos de madera MDF cruda como superficies de apoyo de cámara, espejo y vidrios.<sup>1</sup>

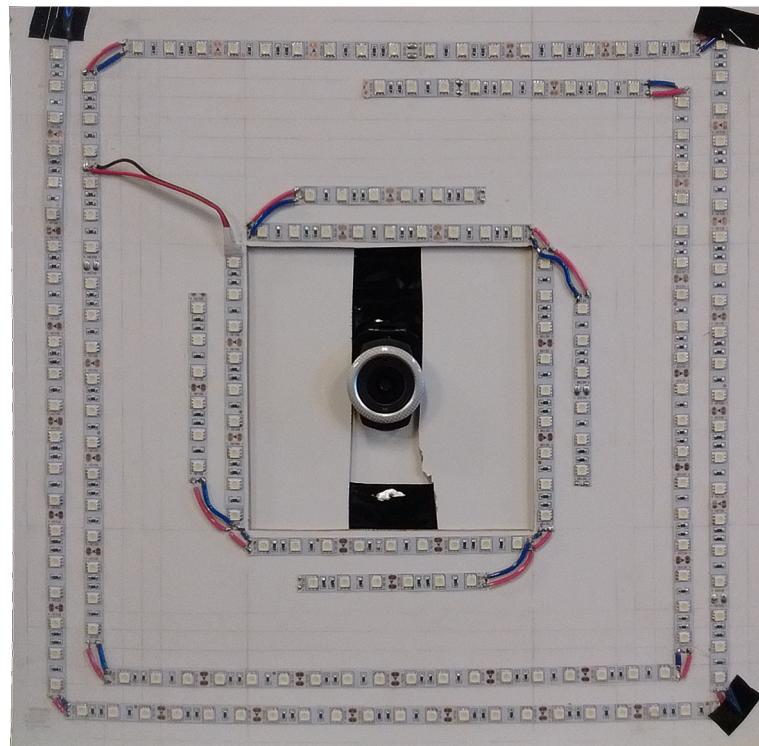
### 3.3 Cámara

Se propuso el uso de una cámara web Genius eFace 2050AF (ver figura 3.5). Sus características principales se muestran en la tabla 3.1.

Se capturaron las imágenes desde Matlab, con la herramienta Image Acquisition Tool de la caja

---

<sup>1</sup>El prototipo construido cumplió sus objetivos pero tiene varios defectos de diseño, que pueden mejorarse. Los orificios rectangulares en los perfiles permiten ajustes finos de nivel, pero sería mucho más conveniente tener una mayor densidad de orificios circulares y cortar los perfiles de forma tal que todos los agujeros estén alineados en altura respecto del suelo. El ajuste con tornillos le da firmeza a la construcción, pero es engorroso de cambiar al hacer pruebas rápidas. Pienso que la solución no fue mala, pero tal vez demasiado ambiciosa para una primera prueba.



**Figura 3.4:** luminaria. Se ha montado la cámara en el orificio central.

**Tabla 3.1:** características principales de la cámara web Genius eFace 2050AF.

Característica	Detalles
Sensor	CMOS 2 megapíxeles
Óptica	Lente de vidrio con autofocus
Interfaz	USB 2.0
Formato	JPEG/WMV
Resolución de foto	1600 × 1200, 1280 × 960, 1280 × 720, 800 × 600, 640 × 480, 352 × 288, 320 × 240, 176 × 144, 160 × 120
Resolución de video	VGA: Hasta 30 FPS 720P: Hasta 9 FPS 1,3 MP: Hasta 9 FPS 2,0 MP: Hasta 6 FPS
Precio	10 USD en 2016. Está discontinuada.



**Figura 3.5:** cámara web Genius eFace 2050AF.

de herramientas homónima. Se usó siempre la máxima resolución disponible ( $1600\text{ px} \times 1200\text{ px}$ ) en formato YUY2. La tasa efectiva de captura de video fue siempre menor a 6 FPS. Se ajustaron manualmente parámetros como la ganancia, el brillo, el contraste, la nitidez y el tono, hasta obtener una representación fiel de la realidad. Se desactivó el autofocus.

La cámara no tiene ajuste manual de apertura o exposición, y tarda varios segundos en ajustarse ante cambios de iluminación. Por otro lado, hace foco a una distancia muy cercana. Por ejemplo, para obtener imágenes nítidas de objetos colocados a 7 cm de la cámara, el parámetro de foco debe estar en su valor mínimo —valores mayores enfocan más cerca—.<sup>2</sup>

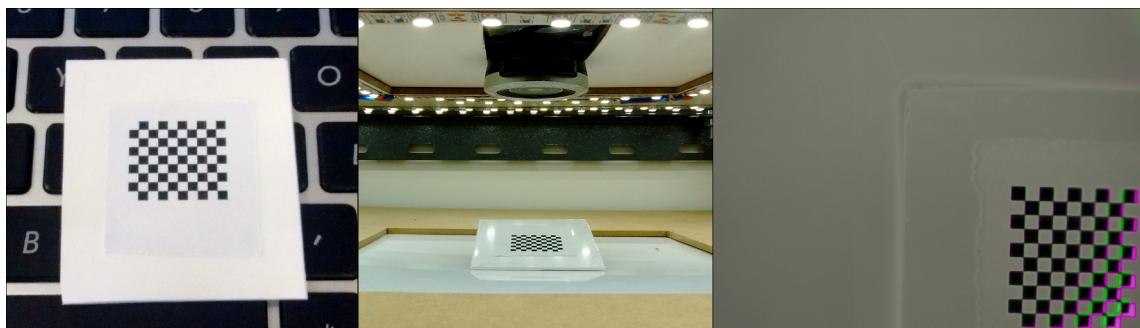
### 3.3.1 Calibración de la cámara

Se llevó a cabo el proceso de calibración geométrica de la cámara, para reducir las distorsiones. Para ello utilizamos un patrón tipo tablero de ajedrez, de  $10 \times 9$  cuadros de 2 mm de lado; este se fotografió en distintas posiciones, ángulos y elevaciones dentro del área visible por la cámara. Las fotos se cargaron a la herramienta Camera Calibration App de Matlab para generar los parámetros del modelo estimado, y luego este modelo se utilizó para corregir la distorsión de todas las imágenes obtenidas.

La distorsión observada es poca, y está concentrada en los laterales izquierdo y derecho de las imágenes. Podría despreciarse. Como ejemplo, ver la figura 3.6: en verde se observa la imagen original, y en rosa la corregida.

---

<sup>2</sup>El tiempo de ajuste ante cambios de iluminación es una gran desventaja en sistemas que utilicen iluminación frontal y retroiluminación de forma alternada, o que apaguen la iluminación para optimizar costos. Además, para obtener buenas imágenes de los objetos, estos deben estar muy cerca de la cámara, lo cual limita el espacio disponible para otros dispositivos. Creo que sería mejor una cámara con mayor posibilidad de ajuste manual, en conjunto con un teleobjetivo que permita alejar la cámara y evitar la incidencia de luz directa proveniente de los iluminadores.



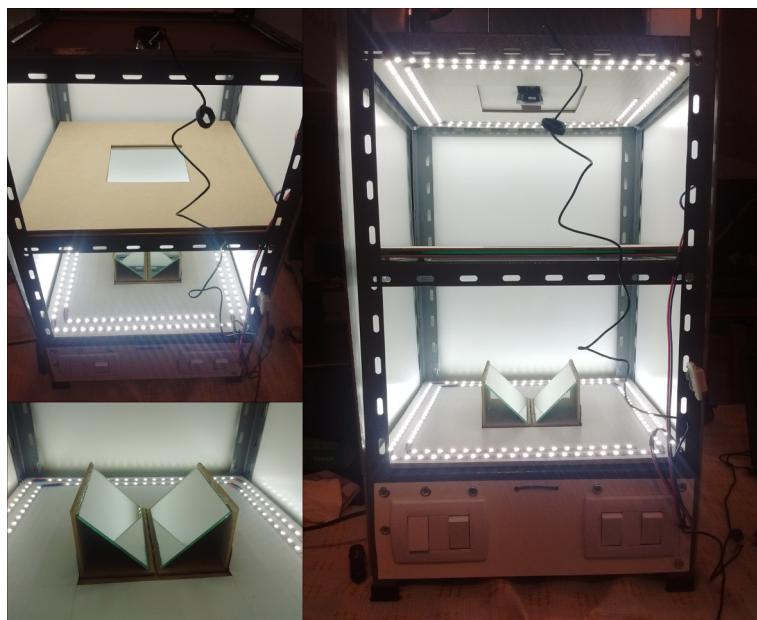
**Figura 3.6:** calibración de la cámara. De izquierda a derecha: patrón de calibración; proceso; resultados. En verde, la imagen original; en rosa, la corregida.

## 3.4 Pruebas de sistemas de visión

Se probaron varios posibles sistemas de visión, para evaluar su desempeño (y posibles implicancias para la máquina real) y para obtener las imágenes con las que se evaluará el algoritmo.

### 3.4.1 Vidrio y espejos

El objeto a analizar se coloca sobre un vidrio transparente, que crea un espacio superior y uno inferior (ver figura 3.7). La cámara se fija en el espacio superior, de forma tal que no recibe luz directa desde la luminaria superior. En el espacio inferior se colocan dos espejos a  $45^{\circ}$  del plano, para generar una imagen del reverso del objeto. De esta manera, anverso y reverso se obtienen en forma simultánea —en realidad, aproximaciones del anverso y del reverso, ya que la cámara está centrada entre ambas imágenes (ver figura 3.8)—.



**Figura 3.7:** configuración de vidrio y espejos: estructura.



**Figura 3.8:** configuración de vidrio y espejos: foto de ejemplo.

Se probaron distintas alturas entre los estantes. Algunos problemas encontrados:

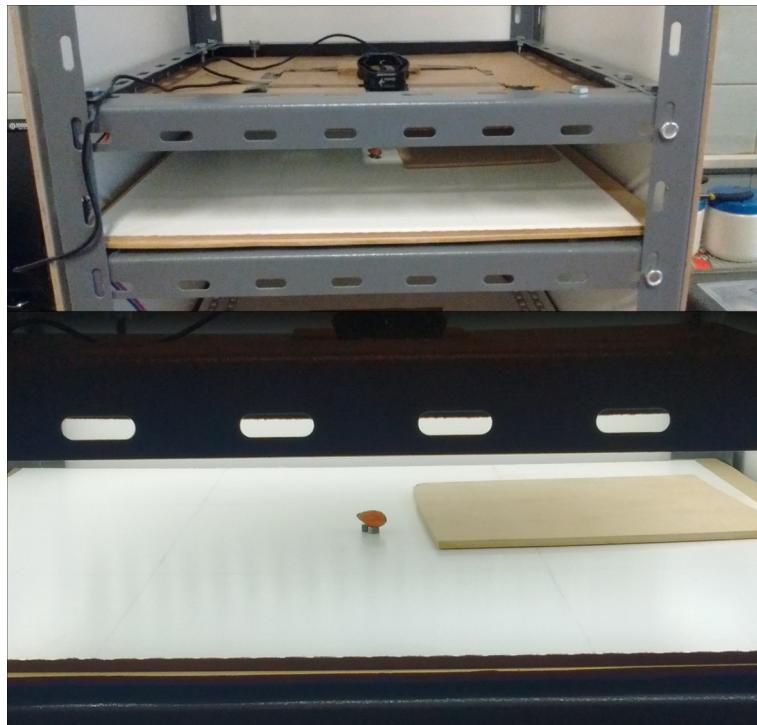
1. La imagen del reverso es muy pequeña.
2. Los espejos generan imágenes fantasma.
3. La cámara tiene problemas para enfocar, agravados por la distancia existente entre los planos de imagen
4. Hay reflejos en el vidrio y en los espejos, que llegan directamente a la cámara.
5. Es complicado disponer la cámara y los espejos para conseguir imágenes de anverso y reverso del objeto con fondo uniforme. El espacio en el que se puede obtener esto es muy pequeño y dependiente de las alturas entre cámara, vidrio y espejos.

Las imágenes fantasma podrían solucionarse con espejos de primera superficie, pero estos son difíciles de conseguir. Los problemas de foco y reflejos directos podrían atenuarse con el uso de un teleobjetivo con un campo de visión angosto. En cuanto a la obtención de un fondo uniforme, se propone ajustar los espejos con ángulos distintos a  $45^\circ$ . En vista de la mala calidad de las imágenes generadas, no se creó un conjunto de imágenes con este sistema.

### 3.4.2 Fondo blanco

El objeto se sitúa sobre una superficie blanca (madera MDF con melamina) muy levemente texturada. La cámara está arriba del objeto, a corta distancia, y solo obtiene una imagen del frente; se supone que existe un mecanismo que da vuelta el objeto para luego tomar una imagen del reverso. La figura 3.9 ilustra esta configuración.

Se generó un conjunto de imágenes (denominado **set2**) con esta configuración. Estuvo limitado a 62 objetos y sirvió para el desarrollo inicial de los algoritmos. Permitió probar, también, que la



**Figura 3.9:** configuración de fondo blanco: estructura.

segmentación por detección de bordes falla cuando hay muy poca diferencia entre el color del objeto y el del fondo; esto sucedía cuando las almendras estaban raspadas en sus bordes, o partidas.<sup>3</sup> A modo de ejemplo, ver la figura 3.10.



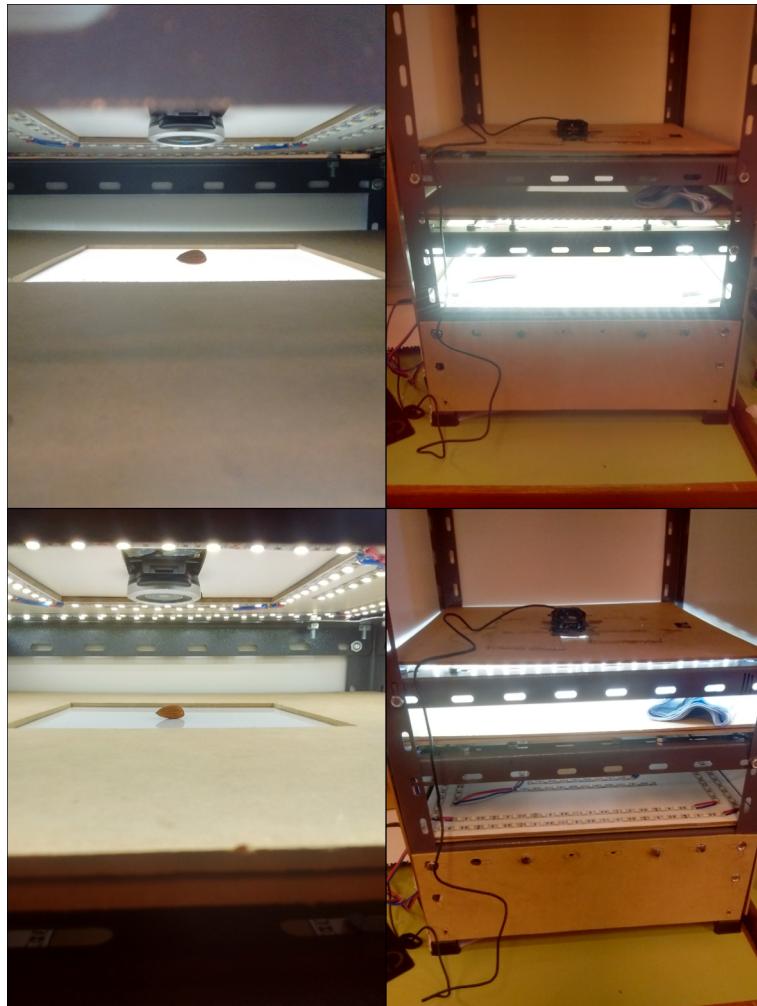
**Figura 3.10:** configuración de fondo blanco (foto de ejemplo).

### 3.4.3 Retroiluminación

El objeto a analizar se coloca sobre una placa de poliestireno de alto impacto de color blanco y 1 mm de espesor a modo de difusor. Se colocan luminarias arriba y abajo de la placa, lo cual permite obtener

<sup>3</sup>La segmentación por detección de bordes (o según el tono) podría funcionar muy bien si el color de fondo contrasta con los colores de los objetos deseados. Un tono celeste es opuesto o complementario al marrón de las almendras y también contrasta con el blanco.

una imagen detallada del objeto, y una del objeto retroiluminado. Esta última presenta un alto contraste entre el fondo (placa iluminada) y el objeto, y esto facilita de gran manera la segmentación precisa del objeto. La cámara está arriba del objeto, a corta distancia, y solo obtiene una imagen del frente; se supone que existe un mecanismo que da vuelta el objeto para luego tomar una imagen del reverso. La figura 3.11 ilustra esta configuración del prototipo. Si bien supone un mayor tiempo para tomar las fotos, esta fue la configuración elegida para armar el conjunto de imágenes final porque asegura una buena segmentación. Este conjunto se detalla en la siguiente sección.



**Figura 3.11:** configuración con retroiluminación: estructura.

### 3.5 Conjunto de imágenes

El conjunto de imágenes elegido como muestra está compuesto por fotos de 564 objetos distintos. Las imágenes se tomaron en el prototipo usando retroiluminación. Este conjunto (denominado set3) es el que se utilizó para evaluar la estrategia de clasificación y para ello fue necesario clasificar manualmente cada objeto.<sup>4</sup>

---

<sup>4</sup>El conjunto se encuentra disponible en [1], junto al set2 y las imágenes de calibración.

### 3.5.1 Condiciones de adquisición

- Cámara Genius eFace 2050AF
- Cámara situada a 6 cm de la superficie.
- Superficie blanca, muy lisa. Brillante. Poliestireno de alto impacto blanco de 1 mm de espesor.
- Un objeto por imagen.
- Cuatro fotos por objeto, dos fotos por cara:
  - Retroiluminación
  - Iluminación frontal
- Tres tapas del prototipo están colocadas. El lado sin tapas es para poder acceder al recinto y colocar los objetos.

### 3.5.2 Procedimiento de adquisición

1. En forma manual, se coloca el objeto sobre la superficie.
2. Se espera unos segundos a que la iluminación frontal deje de variar. Es un ajuste automático de la cámara. La retroiluminación está apagada.
3. Se toma una foto con iluminación frontal.
4. Se apaga la iluminación frontal y se enciende la retroiluminación. Se espera unos segundos a que la imagen deje de variar. Es un ajuste automático de la cámara.
5. Se toma una foto con retroiluminación.
6. Se repite, con el dorso del objeto.

La figura 3.12 muestra las cuatro imágenes generadas para una almendra.

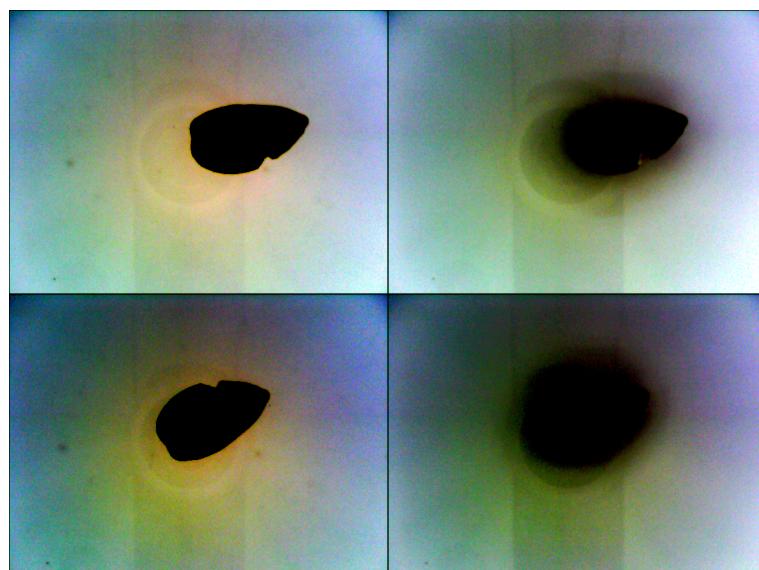
### 3.5.3 Características de las imágenes

La iluminación superior es más uniforme que la del espacio inferior, pero esta última es lo suficientemente uniforme como para permitir una buena segmentación. En las imágenes con iluminación frontal, si bien no se observan reflejos de las luces, sí es posible distinguir un reflejo de la cámara misma (ver figura 3.13). Este reflejo también está en las imágenes de los objetos retroiluminados, pero no afecta a la segmentación.

La información de color en los bordes de los objetos no es buena; esto se puede apreciar en los canales H y S del espacio HSV (ver figura 3.14). Esto puede deberse a la iluminación que incide lateralmente, ya sea en forma directa desde los leds o desde reflejos en las paredes y la base. Fue

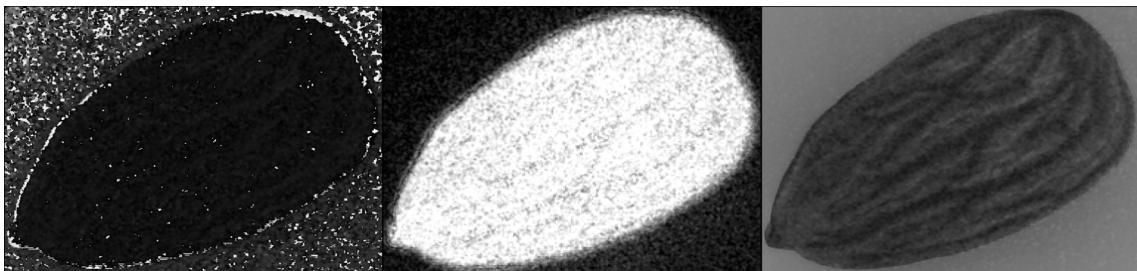


**Figura 3.12:** imágenes de anverso y reverso de una almendra. Izquierda: retroiluminación; derecha: iluminación frontal.



**Figura 3.13:** reflejos sobre la superficie. Imagen de la figura 3.12 con brillo y contraste ajustados para resaltar los reflejos de la cámara y su orificio.

necesario entonces descartar la información de los bordes en los algoritmos que miden características del color del objeto.

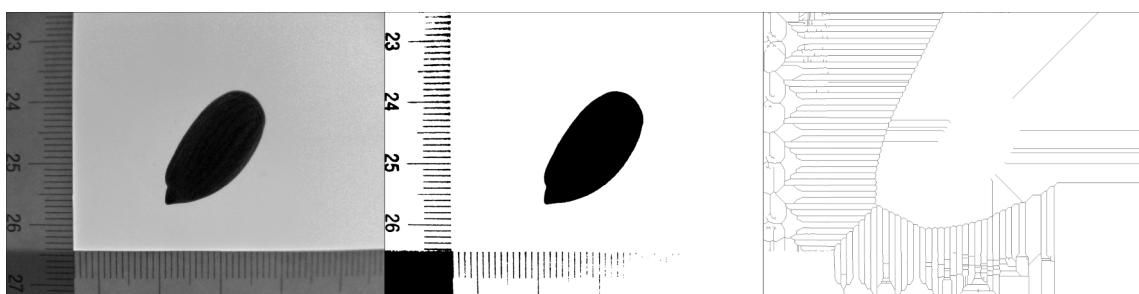


**Figura 3.14:** mala información de color en los bordes. De izquierda a derecha, los canales H, S y V.

El factor de conversión a unidades físicas es de 26 px/mm. Esto se calculó a partir de fotos de cinta métrica. El procedimiento realizado (ver figura 3.15) en GIMP con el complemento G'MIC es:

1. Se convierte la imagen a escala de grises.
2. Se aplica suavizado gaussiano.
3. Se umbraliza la imagen para tener un mayor contraste entre las líneas de medida y el fondo.
4. Se esqueletoniza la imagen.
5. Se miden distancias entre líneas de milímetros.
6. Se calcula un promedio de las distancias medidas.

Este factor también pudo haberse calculado con las imágenes del patrón de calibración, pero eso se hizo en forma posterior a esta medición.



**Figura 3.15:** estimación de factor px/mm. De izquierda a derecha: original tras convertir a gris; suavización y umbralización para mayor contraste; esqueletonización.

### 3.5.4 Clasificación

Dado que no se disponía de subconjuntos etiquetados manualmente por el productor, procedí a clasificar cada objeto en forma manual, basándome mayormente en los criterios establecidos por la norma de UNECE.

## Criterios

Se listan a continuación los criterios evaluados en cada almendra u objeto, para considerarlos defectuosos. Es importante advertir que muchos de los criterios (como el color) no han sido medidos objetivamente, y por tanto las mediciones pueden tener errores o no ser representativas del conjunto.



**Sucia** Si está manchada con barro u otros elementos extraños, o tiene mucho polvo.

**Fuera de tamaño** La altura de cada almendra u objeto es la medida automáticamente por uno de los clasificadores desarrollados; específicamente, es la altura de la caja de menor tamaño que contiene al objeto en la imagen. Se considera exacta.

La norma de UNECE no define límites exactos para los tamaños, ya que estos varían entre especies y cosechas. Por tanto, simplemente se excluye a las almendras cuyo tamaño difiere mucho del resto.

Para definir límites, se calcula la media  $\mu$  y la desviación estándar  $\sigma$  de las alturas de todas las almendras, excluyendo las consideradas como deformadas y las partidas. Se establece el rango de tamaños válidos en  $[\mu - 2\sigma, \mu + 2\sigma]$ , lo que determina un intervalo de confianza del 95,4 % para una distribución normal o gaussiana.



**Deformada** Si tiene una forma distinta a la característica de la variedad.



**Color malo** Si presenta un color distinto al característico de la variedad.



**Podrida o con daño de insectos** Si tiene rasgos de descomposición visibles, o presencia de hongos.



**Doble** Las almendras dobles o gemelas tienen uno de sus lados lisos o cóncavos, como consecuencia del desarrollo de dos semillas dentro de la misma cáscara.



**Extremadamente lisa** Una almendra que no presenta el nivel de arrugas característico de la variedad.



**Arrugada** Una almendra que está excesivamente arrugada o seca, que ha perdido volumen y es estéticamente distinta al resto.



**Astillada** Si ha sufrido daño mecánico y falta menos de 1/4 de la semilla. No se considera defecto si la parte faltante total sumada es menor (en el plano) al área de un círculo de 3 mm de diámetro.



**Raspada** Se midió manualmente el área total sin tegumento de cada lado de cada almendra, en píxeles. Luego se sumaron y convirtieron a cm<sup>2</sup>. La almendra se considera raspada si el área medida es mayor al área de un círculo de 3 mm de diámetro.



**Mitad** Si es un cotiledón separado del otro.



**Partida** Una almendra a la cual le falta más de 1/4 de la semilla.



**Fragmento** Un pedazo de semilla que pasa a través de una malla con orificios redondos de 10 mm de diámetro.



**Puntos marrones** Puntos de color marrón oscuro, ligeramente deprimidos, causados por la picadura de insectos. El área total sumada de los puntos no debe ser mayor que el área de un círculo de 3 mm de diámetro. No deben confundirse con círculos marrones de tamaño considerable que se encuentran en la base de algunas semillas y se consideran normales.



**Manchas de color** Zonas dispersas con un color distinto a los característicos de la variedad, afectando a más de un cuarto de la almendra.



**No almendra** Ramas, piedras, tierra, cáscaras, carozos, y todo aquello que no sea una semilla.



**En buen estado** Si no tiene ningún defecto observable.

## Etiquetas

Establezco tres etiquetas o clases:

**Buena** si se trata de una almendra en buen estado.

**Mala** si tiene uno o más defectos.

**No almendra** si se trata de otro objeto.

## Resultados

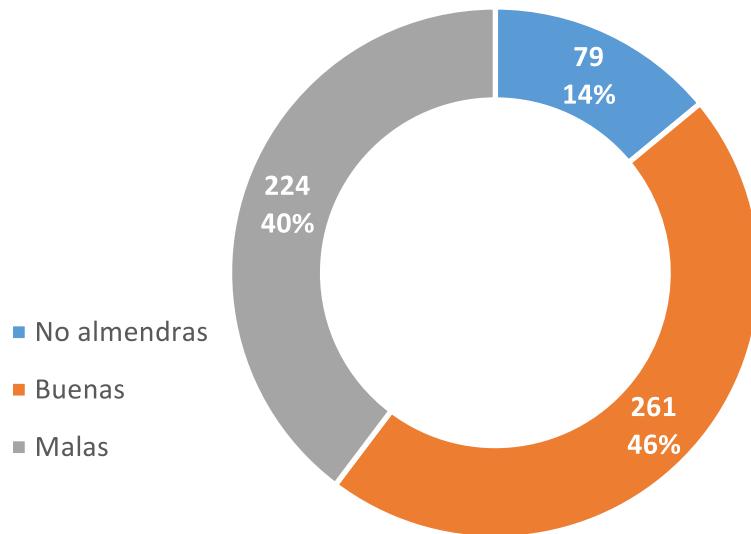
Se etiquetaron 261 almendras buenas, 224 almendras malas y 79 objetos que no son almendras. La tabla 3.2 detalla los resultados; nótese que la suma excede los 564 objetos ya que cada uno puede acumular más de un defecto.

**Tabla 3.2:** composición del conjunto set3.

Etiqueta o defecto	Cantidad
Sucia	7
Fuera de tamaño	97
Deformada	1
Color malo	12
Podrida / con daño de insectos	12
Doble	0
Extremadamente lisa	2
Arrugada o marchita	31
Astillada	10
Raspada	36
Mitad	8
Partida	43
Fragmento	52
Con puntos marrones	1
Con manchas	0
No almendra	79
Buena	261

## 3.6 Partición y preprocesado

El conjunto se dividió en dos subconjuntos: uno de entrenamiento y otro de evaluación, con el 80 % y el 20 % de las muestras respectivamente —esta proporción se mantiene para cada una de las tres clases—. Los parámetros de los algoritmos se ajustaron en base a lo medido en el conjunto de entrenamiento; el de evaluación sirve como prueba independiente para probar lo ajustado —y verificar que no esté sobreajustado— . Se corrigieron las distorsiones de cada imagen, en base a los parámetros de la cámara



**Figura 3.16:** composición del conjunto set3.

obtenidos en la calibración. Además, para eficiencia de almacenamiento y para aliviar la carga de procesamiento, todas las fotos fueron recortadas.

## 4 Estrategia de clasificación

### 4.1 Esquema general e implementación

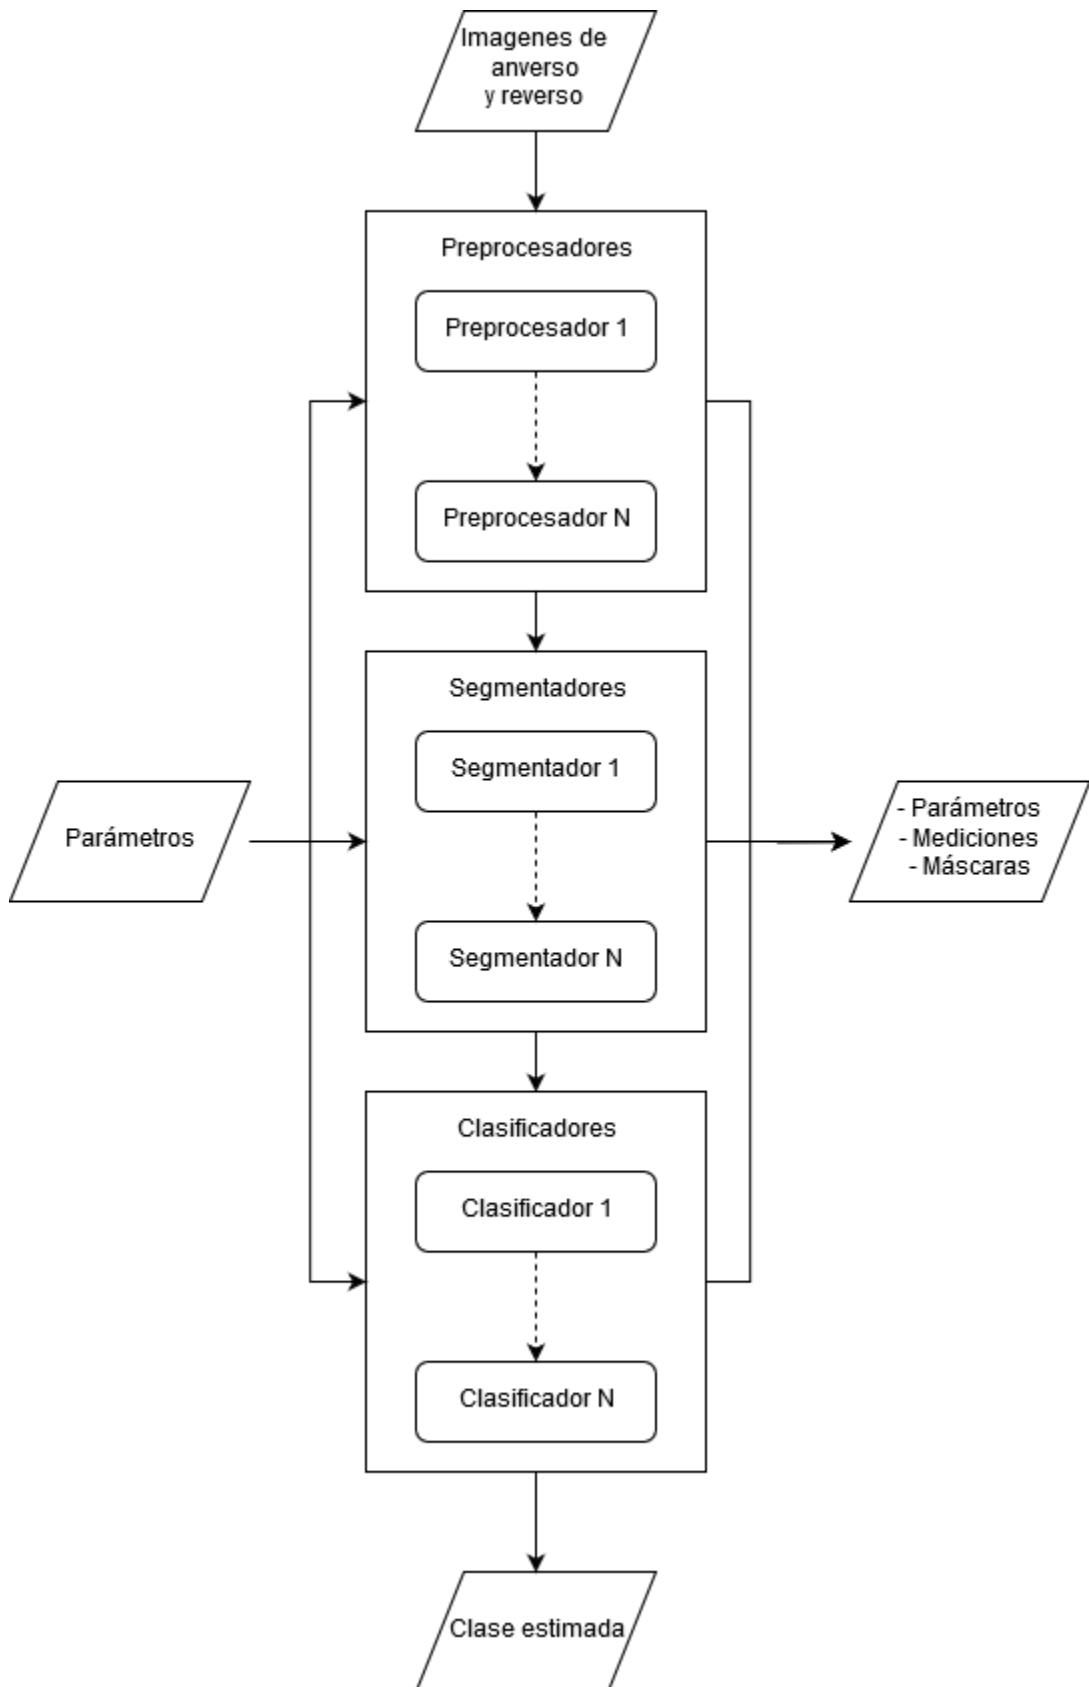
Buscamos determinar un conjunto de características (y sus valores) que permita distinguir correctamente a las almendras buenas de aquellas que están defectuosas o son objetos extraños. Además, la definición de «defectuosa» o «mala» debe ser variable, para permitirle al usuario modificar arbitrariamente la calidad de los productos obtenidos. Esto implica un proceso extenso de experimentación, ya que existe una gran cantidad de atributos a analizar y formas de definirlos explícitamente. Creímos necesaria entonces una arquitectura con los siguientes rasgos:

1. Debe servir para experimentar pero también debe poder expresarse como un potencial producto.
  - a) Debería tener una interfaz gráfica de usuario o *GUI* para ajustar parámetros y verificar funcionamiento.
  - b) Los parámetros deben poder modificarse fácilmente, y preferiblemente en línea.
2. Es modular. Permite probar distintos algoritmos clasificadores, y la adición o eliminación de un nuevo módulo no afecta a los otros.

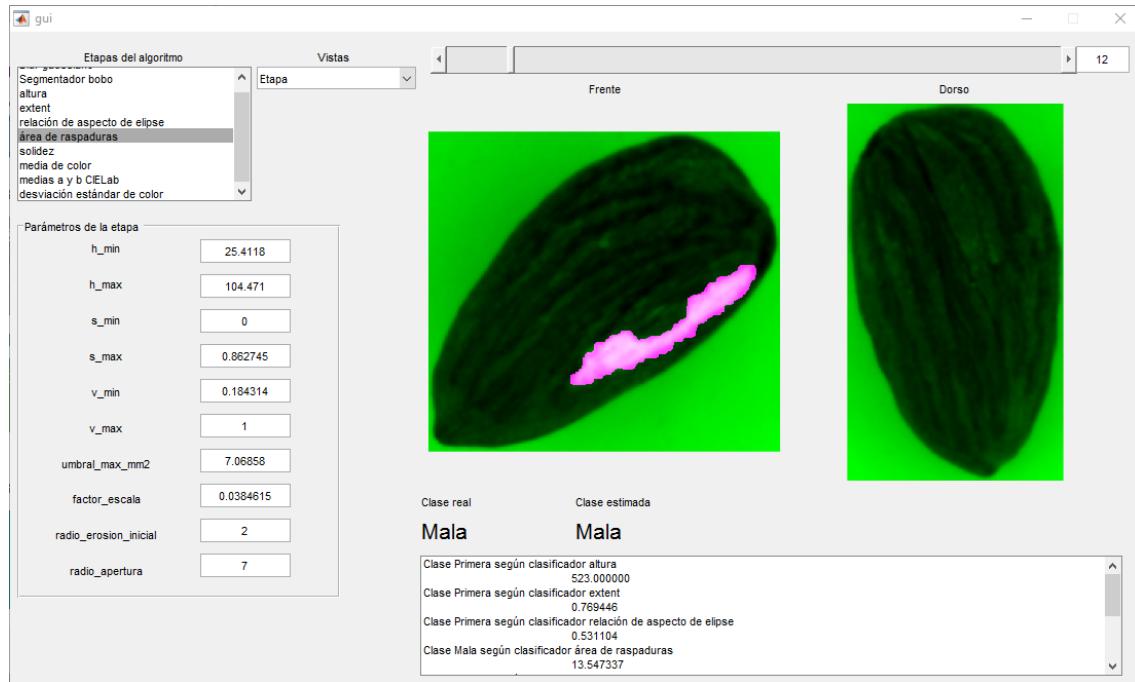
En pos de lo anterior, la implementación se basa en un sistema compuesto por una secuencia de etapas que van transformando y analizando las imágenes correspondientes al anverso y reverso de cada objeto (ver figura 4.1). Estas imágenes pueden provenir directamente de una cámara o ser cargadas desde archivos guardados previamente. Cada etapa tiene parámetros variables que pueden modificarse en línea, y además genera resultados (mediciones, imágenes, metainformación) que pueden conocerse en línea.

El sistema se implementó en Matlab y se basa en el paradigma de programación orientada a objetos, lo que posibilita (entre otras cosas) un fácil desarrollo de etapas similares a través de la herencia. Las etapas están agrupadas en tres clases: Preprocesadores, Segmentadores y Clasificadores. La configuración de los parámetros variables de cada etapa se hace mediante archivos YAML, de fácil generación y lectura. Las mediciones realizadas y los resultados se pueden exportar como tablas XLS.

La interfaz gráfica de usuario realizada (ver figura 4.2) es básica y sirve mayormente para la depuración de los algoritmos. Permite ver y modificar todos los parámetros de cada una de las etapas de un algoritmo, mostrando también imágenes auxiliares de cada etapa y un registro escrito de los resultados de clasificación.



**Figura 4.1:** esquema general de funcionamiento de la implementación realizada. Nótese que el orden de las etapas no es fijo.



**Figura 4.2:** interfaz gráfica de usuario.

### 4.1.1 Preprocesamiento

El preprocesamiento sirve para mejorar el desempeño de las etapas subsiguientes. Las imágenes con las que trabajamos tienen buena iluminación y poco ruido, por lo que solo se implementó un filtrado gaussiano básico. Otras posibles etapas preprocesadoras podrían ajustar o normalizar los niveles de iluminación o los colores, o reducir el ruido con otros algoritmos. También podrían normalizarse los tamaños de los objetos una vez segmentados, si esto fuese necesario para el cálculo de algún descriptor específico.

### 4.1.2 Segmentación

Segmentar una imagen es subdividirla en sus regiones u objetos constituyentes. El nivel de detalle con el cual se realiza la subdivisión depende del problema que quiere resolverse; esto es, la segmentación se detiene cuando los objetos o las regiones de interés de la aplicación se han detectado. La segmentación de imágenes no triviales es una de las tareas más complejas del procesamiento digital de imágenes, y la precisión alcanzada determina el eventual éxito o fracaso de los procedimientos de análisis. [23]

Esta etapa es muy dependiente de las características generales de las imágenes, y por tanto dependiente de la forma en que las imágenes se crean. Si esto último es modificable (como en el caso que nos compete, porque estamos diseñando tanto la captura como el procesamiento), el diseñador tiene un grado de libertad extra para elegir la estrategia de segmentación óptima. [23]

En este trabajo experimentamos con segmentación según colores, a partir de bordes y basada en el nivel de gris de un objeto retroiluminado.

### 4.1.3 Clasificación

Cada etapa de clasificación calcula un único descriptor visual o *feature*, y clasifica al objeto, según el valor obtenido, en una de tres clases: **Primera<sup>1</sup>**, **Mala** o **No Almendra**. Las etapas clasificadoras son autocontenidoas e independientes entre sí, lo que da la libertad de quitar, añadir o cambiar el orden de las etapas.

Inicialmente, todos los objetos se presuponen almendras de Primera; luego cada etapa puede ir degradando o manteniendo la clase. Se contempla la posibilidad de que el sistema termine prematuramente la clasificación de un objeto, si este ya ha sido calificado como Mala o No Almendra. Si esto está activado y además se ordenan las etapas en forma creciente según su complejidad de procesamiento, el sistema funciona de forma similar a las cascadas de clasificadores usadas para la detección de objetos. También puede verse como un árbol de decisiones de una sola rama.

## 4.2 Etapas de segmentación

A continuación se definen algunas cuestiones comunes a varios algoritmos de segmentación, y luego se describe brevemente el funcionamiento de cada uno. Cada algoritmo tiene:

**Entrada principal** Imágenes RGB del objeto.

**Entradas complementarias** Valores de los parámetros variables del algoritmo.

**Salida principal** Imagen binaria. En blanco (o «verdadero» lógico), los píxeles correspondientes al objeto encontrado. En negro (o «falso» lógico), los que corresponden al fondo.

**Salidas complementarias** Mediciones realizadas por el algoritmo, e imágenes auxiliares para depuración.

Recordamos que hemos supuesto que solo hay un objeto por imagen (ver 3.1.4), por lo que en caso de encontrar varios solo se reconocerá el de mayor tamaño.

### 4.2.1 Definiciones

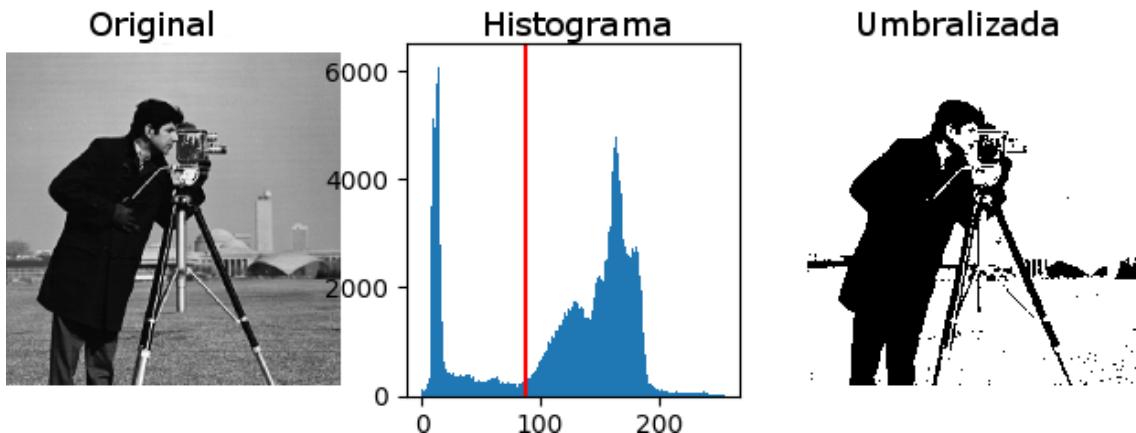
#### Umbralización con el método de Otsu

La umbralización es una función no lineal que convierte un rango de valores de entrada en solamente dos valores de salida. Esta operación es muy útil para poder separar el contenido de una imagen en dos clases; los resultados dependerán de cuáles son los umbrales que se establecen para determinar el límite entre las dos clases.

---

<sup>1</sup>Contemplando una posible extensión para clasificar almendras de segunda calidad.

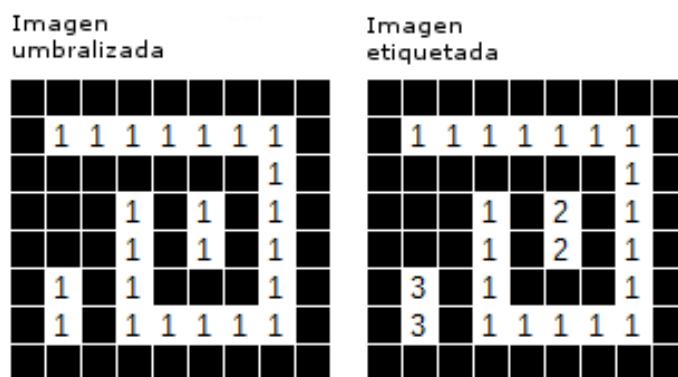
El método de Otsu es una forma no iterativa de encontrar el umbral óptimo global que segmenta una imagen en dos clases. [24] Es óptimo en el sentido de que maximiza la varianza interclase —o, equivalentemente, minimiza la varianza intraclasa—. Su cálculo se basa en el histograma de intensidades de la imagen (de un canal) y funcionará mejor mientras más bimodal sea la distribución de intensidades.<sup>2</sup> La figura 4.3 ilustra su funcionamiento y resultados.



**Figura 4.3:** método de Otsu. La línea roja en el histograma marca el umbral calculado. [25]

### Etiquetado de componentes conectados

El etiquetado de componentes conectados consiste en agrupar los píxeles de una imagen binaria en tantas clases como objetos haya, considerando como pertenecientes al mismo objeto a aquellos píxeles que están conectados entre sí. La definición de conectividad puede variar. La figura 4.4 ilustra el proceso.



**Figura 4.4:** etiquetado de componentes conectados. [26]

La operación también se conoce como extracción de componentes conectados, y a estos últimos se los puede denominar regiones o *blobs*.<sup>3</sup>

<sup>2</sup>Hay optimizaciones al método de Otsu, como el llamado método de Otsu bidimensional.

<sup>3</sup>BLOB: retroacrónimo de *Binary Large Object*.

### 4.2.2 Detección de bordes sobre fondo blanco

Esta estrategia<sup>4</sup> fue diseñada sobre imágenes del conjunto de imágenes set2 (el obtenido con el sistema de visión con fondo blanco —ver 3.4.2—). Consiste en:

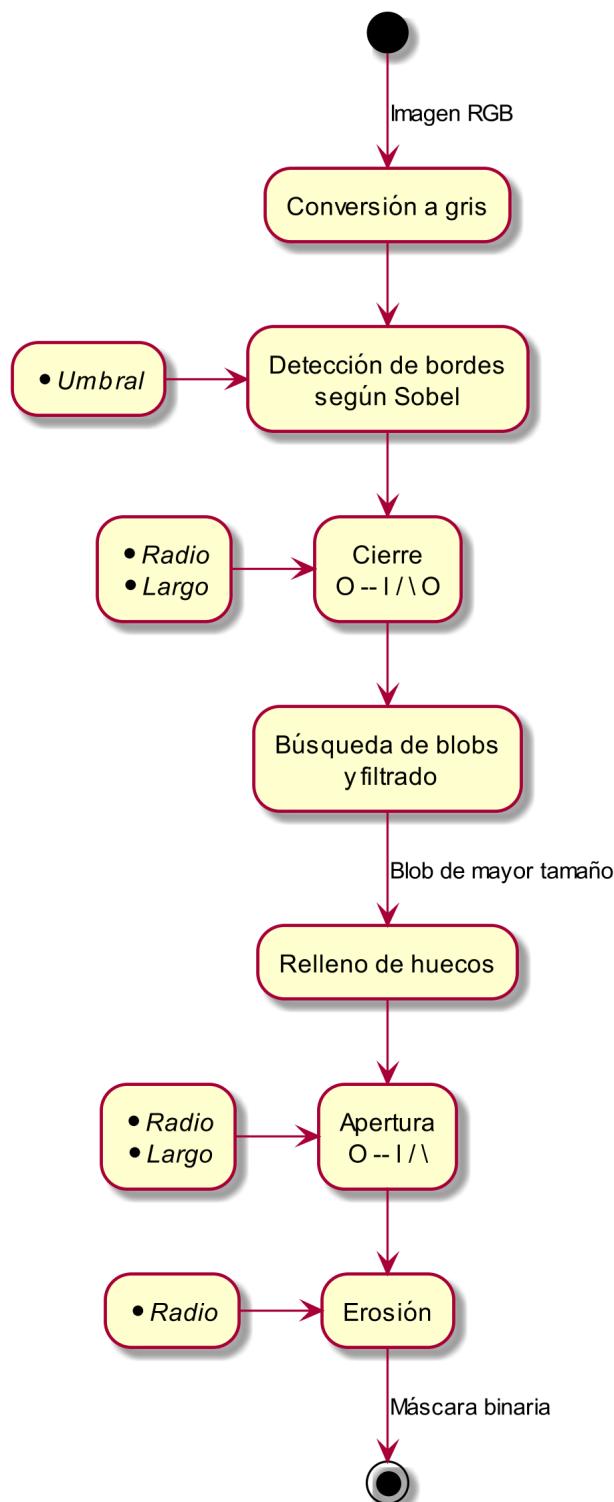
1. Se convierte la imagen RGB (con iluminación frontal) a escala de grises.
2. Se detectan bordes utilizando la aproximación de Sobel para la derivación. La imagen obtenida es binaria, con valor 1 en donde la derivada supere cierto valor de umbral.
3. Filtrado morfológico para conectar bordes y filtrar *blobs* pequeños. Como elementos estructurantes se utilizan un disco y líneas a distintos ángulos ( $0^\circ, 90^\circ, 45^\circ, -45^\circ$ ), en secuencia, para la operación de cierre (erosión luego de dilatación).
4. Se extraen los componentes conectados y se elige el de mayor área.
5. Se rellenan los huecos de la región resultante.
6. Se aplican operaciones morfológicas para suavizar los bordes: apertura (dilatación luego de erosión) con disco y líneas a distintos ángulos para contemplar diversos defectos.
7. Finalmente, se erosiona la imagen con un disco. Esto es para reducir el tamaño de la máscara, en caso de que sea mayor al objeto real.

Los parámetros variables son el umbral de detección de bordes y los radios y longitudes de discos o líneas utilizados en las operaciones de cierre, apertura y erosión.

La detección de bordes falla si hay poco contraste entre el fondo y el objeto, lo cual ocurrió entre el fondo blanco y las zonas de carne de las almendras. Podría mejorarse con un fondo de algún color que contraste con todos los elementos de interés, garantizando además que no ingresen al sistema objetos que tengan colores similares al del fondo.

---

<sup>4</sup>Ver clase SegmentadorBorde1.m.



**Figura 4.5:** algoritmo de segmentación por detección de bordes sobre fondo blanco.

### 4.2.3 Retroiluminación + umbral en gris

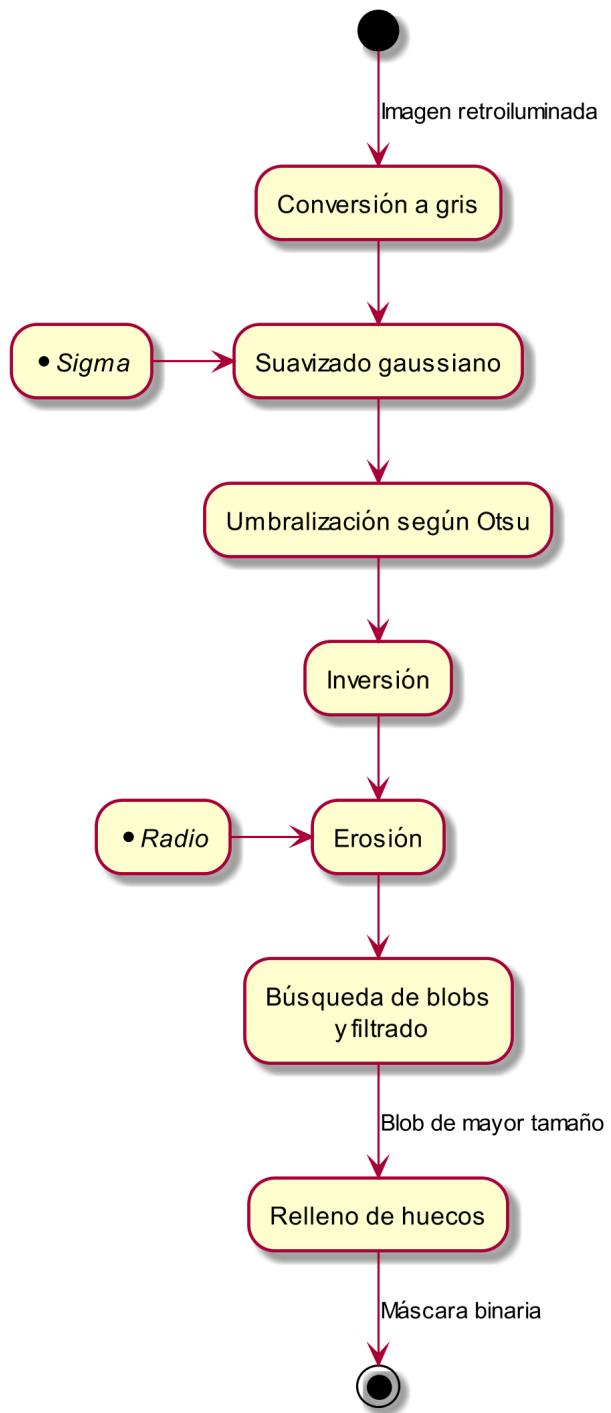
Este segmentador<sup>5</sup> se diseñó en base a las imágenes que forman el conjunto de imágenes set3. El algoritmo trabaja con la imagen del objeto retroiluminado, y es el siguiente:

1. Se convierte la imagen RGB a escala de grises.
2. Se aplica suavizado gaussiano, para reducir el nivel de ruido y suavizar bordes.
3. Se umbraliza la imagen con el método de Otsu.
4. Se aplica inversión binaria para que el fondo sea negro (o «falso») y el objeto blanco (o «verdadero»).
5. Se erosiona la máscara con un disco para reducir su tamaño, en caso de que sea grande. Esto también elimina objetos pequeños, lo que simplifica el siguiente paso.
6. Se extraen los componentes conectados y se elige el de mayor área.
7. Se rellenan los huecos existentes.

Los parámetros variables son el radio del disco que erosiona y la desviación estándar  $\sigma$  del núcleo de suavizado. Los resultados obtenidos son muy precisos, siempre y cuando se garantice que el objeto está en la misma posición tanto en la imagen con retroiluminación como en la de iluminación frontal.

---

<sup>5</sup>Ver clase SegmentadorRetroiluminacion.m.



**Figura 4.6:** algoritmo de segmentación por umbralización de la imagen retroiluminada.

#### 4.2.4 Umbralización del tono

Esta opción<sup>6</sup> se probó en etapas iniciales del proyecto, con fotos de objetos sobre mesas de color y basándonos en lo hecho en [27]. El proceso es el siguiente:

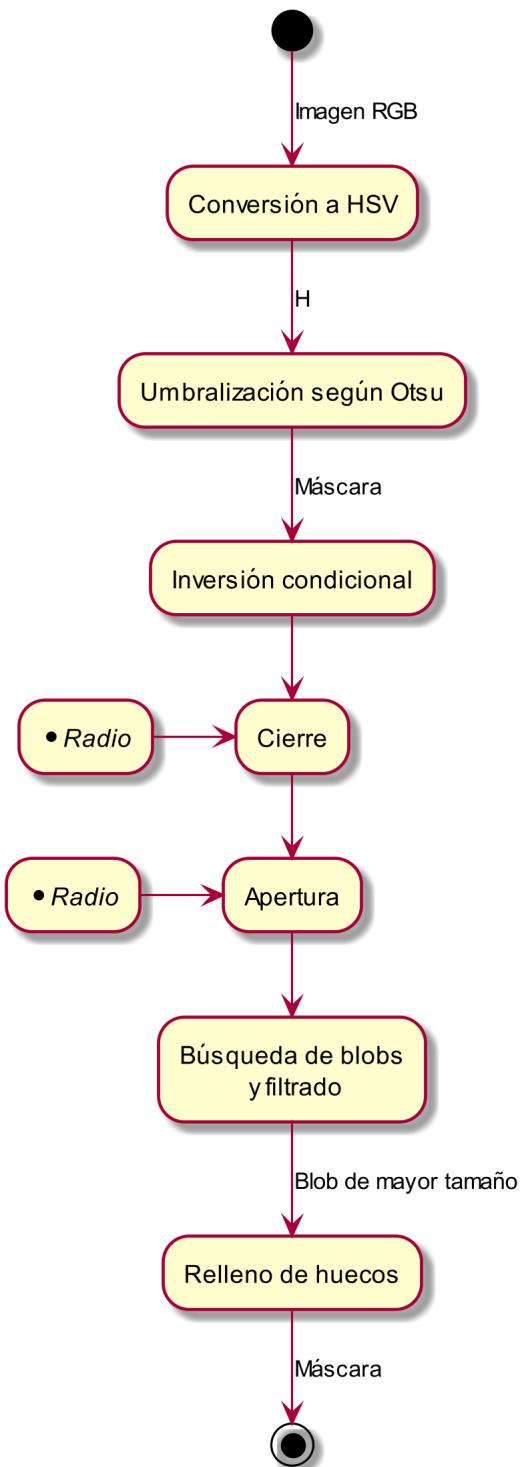
1. Se convierte la imagen RGB al espacio HSV. Se trabajará con el canal H.
2. Umbralización del canal H según el método de Otsu.
3. Inversión condicional. Se supone que hay más fondo que objeto; entonces, si los píxeles que corresponden al fondo de la imagen se han clasificado como de color blanco (o valor «verdadero»), se invierte toda la imagen.
4. Cierre morfológico con disco.
5. Apertura con disco.
6. Se extraen los componentes conectados y se elige el de mayor área.
7. Se rellenan los huecos existentes.

Los parámetros variables son los radios de los discos de cierre y apertura.

Esta estrategia funciona si hay un fondo de un color uniforme que contraste con todos los objetos posibles.

---

<sup>6</sup>Ver clase SegmentadorHue1.m.



**Figura 4.7:** algoritmo de segmentación por umbralización del canal H (matiz).

## 4.3 Etapas clasificadoras

A continuación definimos algunas cuestiones comunes a varios etapas de clasificación, y luego describimos brevemente el funcionamiento de cada una. Cada etapa tiene:

**Entradas principales** imágenes RGB del objeto, máscaras.

**Entradas complementarias** valores de los parámetros variables del algoritmo.

**Salida principal** valor(es) del descriptor.

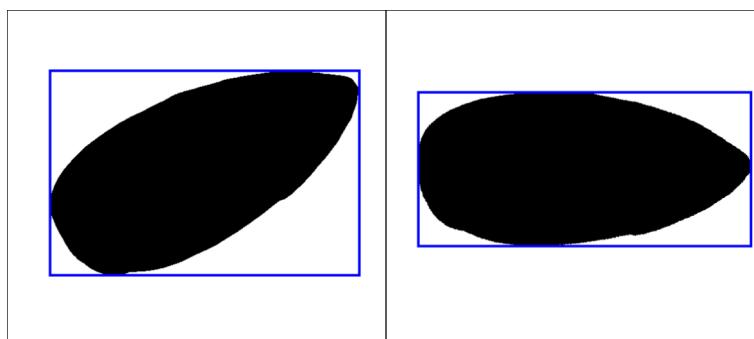
**Salidas complementarias** Otras mediciones realizadas por el algoritmo, e imágenes auxiliares para depuración.

### 4.3.1 Definiciones

#### Caja envolvente

La (mínima) caja envolvente (o *bounding box*) es el rectángulo de menor tamaño que contiene a todos los elementos de un conjunto de píxeles en el plano. Trabajando con imágenes binarias, una caja contiene a todos los píxeles de un *blob* dado.

La implementación de Matlab calcula las coordenadas de una caja o rectángulo con una de sus caras paralela al eje horizontal, y esto no garantiza que la caja sea mínima. Esta también se conoce como «caja envolvente horizontal» (*horizontal bounding box*).

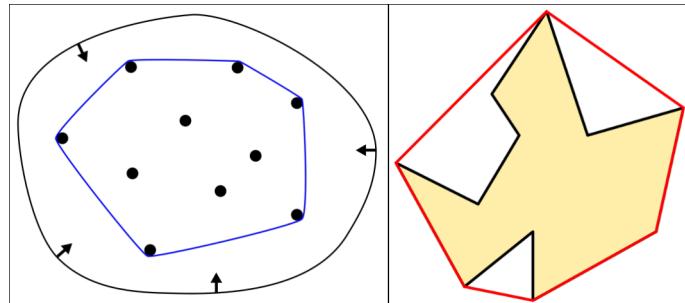


**Figura 4.8:** caja envolvente. En azul, las cajas horizontales calculadas para cada objeto.

#### Envolvente convexa

La envolvente convexa (*convex hull*) de un conjunto de puntos  $P$  es la intersección de todos los conjuntos convexos que contienen a  $P$ . Una conjunto  $C$  de un espacio vectorial real es convexo si para cada par de puntos de  $C$ , el segmento que los une está totalmente incluido en  $C$ ; es decir, un conjunto es convexo si se puede ir de cualquier punto a cualquier otro en línea recta, sin salir del mismo.

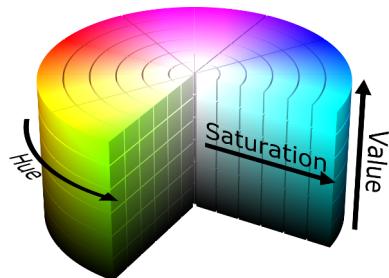
Gráficamente, la envolvente convexa en el plano puede ser visualizada como el área determinada por una banda elástica que envuelve a todos los puntos de interés.



**Figura 4.9:** envolvente convexa. En azul y en rojo se muestran las envolventes para cada conjunto. [28, 29]

### Medidas estadísticas del matiz

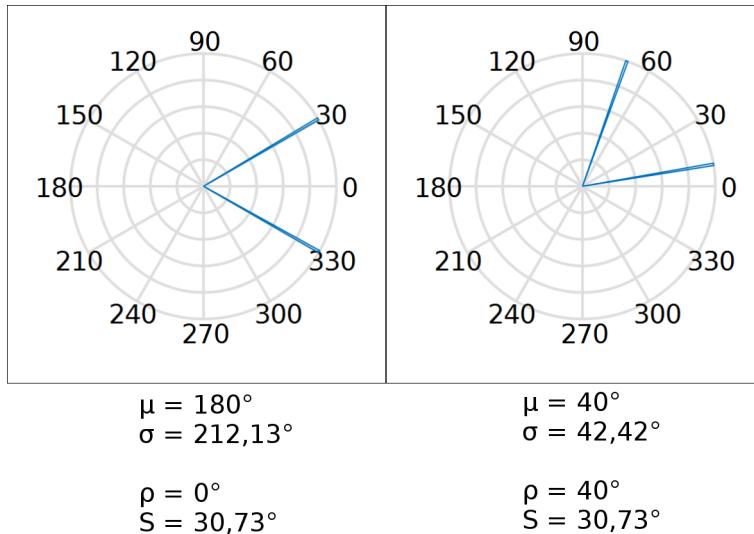
El espacio de color HSV es una forma de modelar los colores; en este caso, se expresan en un espacio de coordenadas cilíndricas: matiz (*hue*, también conocido como tono o tonalidad), saturación (*saturation*) y valor (*value*, o luminosidad). Podemos asociar el tono con los colores más «puros», sin mezclarlos con color blanco o negro. En el espacio cilíndrico HSV el tono corresponde al ángulo y por tanto su rango es de  $[0^\circ, 360^\circ]$ .



**Figura 4.10:** espacio HSV. [30]

Cuando hablamos del matiz así definido, utilizar medidas típicas de tendencia central (como la media aritmética, la media geométrica o la mediana) o de dispersión (como la varianza o la desviación estándar) es incorrecto, ya que producen resultados que no siempre representan las características de la distribución de los datos. Supóngase, por ejemplo, que se tiene una muestra en  $30^\circ$  y otra en  $330^\circ$  (ver figura 4.11): la media aritmética  $\mu$  es  $180^\circ$ , cuando la intuición indica que debería ser  $0^\circ$ . Análogamente, la desviación estándar  $\sigma$  es de  $212,13^\circ$ , pero si rotamos todo  $40^\circ$  (resultando en los ángulos  $10^\circ$  y  $70^\circ$ ), la desviación es tan solo de  $42,42^\circ$ .

Surge como solución la estadística direccional, circular o esférica, que trata con rotaciones, ejes y direcciones. Se aplica también para describir fenómenos que ocurren en ciclos temporales, tal como días y años.



**Figura 4.11:** medidas estadísticas en ángulos.  $\mu$  y  $\sigma$  son la media y la desviación estándar de uso convencional, mientras que  $\rho$  y  $S$  son la media y la desviación estándar según la estadística direccional.

Se determinan a continuación la media circular y la desviación estándar circular, que se usaron como descriptores de color. [31]

Sea un conjunto de  $n$  ángulos  $a_1, a_2, \dots, a_n$ . Estos pueden interpretarse como  $n$  vectores  $v$  de magnitud 1 y ángulos  $a_1, a_2, \dots, a_n$  respectivamente:

$$v_n = 1 e^{j a_n} \quad (4.1)$$

Si se convierten a coordenadas cartesianas, se tiene:

$$v_n = \cos(a_n) + j \sin(a_n) \quad (4.2)$$

Sumando los  $n$  vectores obtenemos el vector resultante  $a$ :

$$a = \sum_1^n v_n = R e^{j \rho} \quad (4.3)$$

La **media circular** (o **ángulo medio** en este caso) es el ángulo  $\rho$  descripto por este vector resultante  $a$ . La longitud media de los vectores  $v_n$  se define como:

$$\bar{R} = \frac{R}{n} \quad (4.4)$$

Y la **desviación estándar circular** como:

$$S = \sqrt{\ln\left(\frac{1}{\bar{R}^2}\right)} = \sqrt{-2 \ln(\bar{R}^2)} \quad (4.5)$$

### 4.3.2 Descriptor 1: altura de caja envolvente

La característica analizada es la altura del objeto.<sup>7</sup> El estimador usado es la media de las alturas de las cajas envolventes que encierran el anverso y el reverso del objeto. La caja envolvente no es la mínima posible; en este trabajo usamos la caja envolvente horizontal calculada luego de horizontalizar la imagen según la orientación del eje mayor de una elipse ajustada al *blob*.

Se establecen tanto un valor máximo como un mínimo, ya que las almendras deben mantener uniformidad de tamaño.

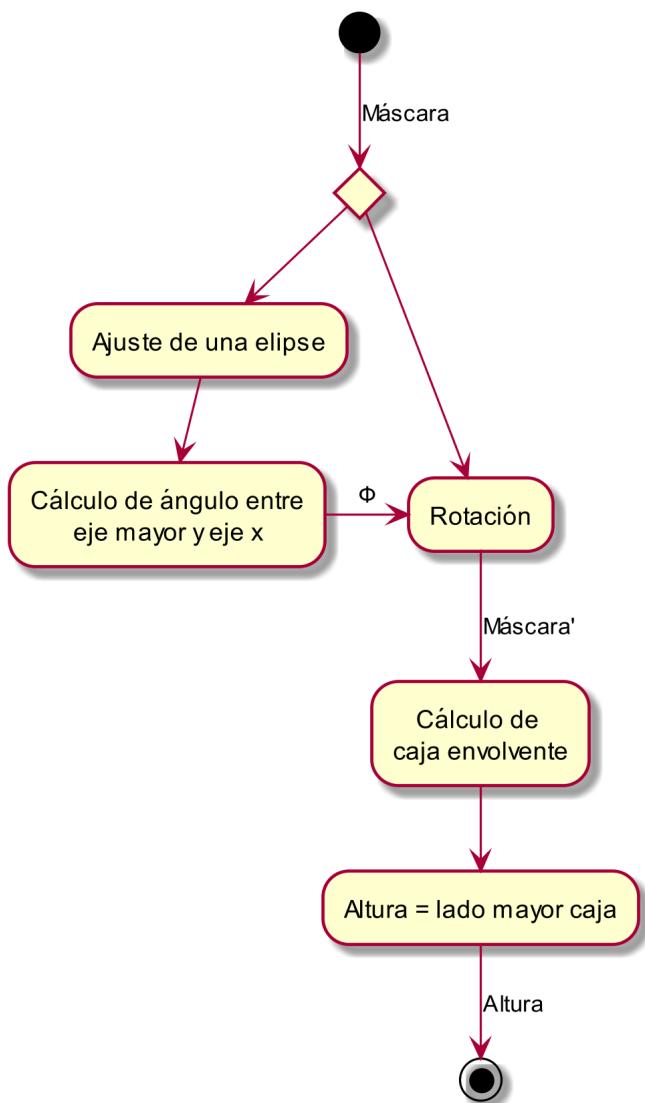
Este descriptor es bastante exacto, robusto y solo depende de la máscara que delimita al objeto. También podría estimarse a partir del eje mayor de una elipse que se ajusta al *blob*.

El algoritmo es:

1. Se ajusta una elipse al objeto.
2. Se horizontaliza la imagen, rotándola un ángulo igual (pero de signo opuesto) al descripto entre el eje mayor de la elipse y el eje *x*.
3. Se calcula la caja envolvente del objeto rotado.
4. Se calcula la altura de la caja, que es el largo del lado mayor.

---

<sup>7</sup>Ver clase ClasificadorAltura.m.



**Figura 4.12:** esquema del cálculo del descriptor 1 (altura de la caja envolvente).

### 4.3.3 Descriptor 2: proporción de arrugas

Se estima la proporción de área arrugada de cada cara como la proporción total de área oscura, según un valor de V —se supone que las sombras indican presencia de arrugas—.<sup>8</sup> La métrica final es la media de los valores medidos en cada lado. Esto permite que no se etiqueten erróneamente como malas a almendras que tienen puntos oscuros grandes cerca de su base. En general las almendras arrugadas lo están en ambos lados.

$$\text{proporción de arrugas} = \frac{\text{área oscura}}{\text{área total de objeto}} = 1 - \frac{\text{área no oscura}}{\text{área total de objeto}} \quad (4.6)$$

Se establecen como parámetros variables un valor máximo tolerable para la proporción de arrugas, y un valor de V para umbralizar.

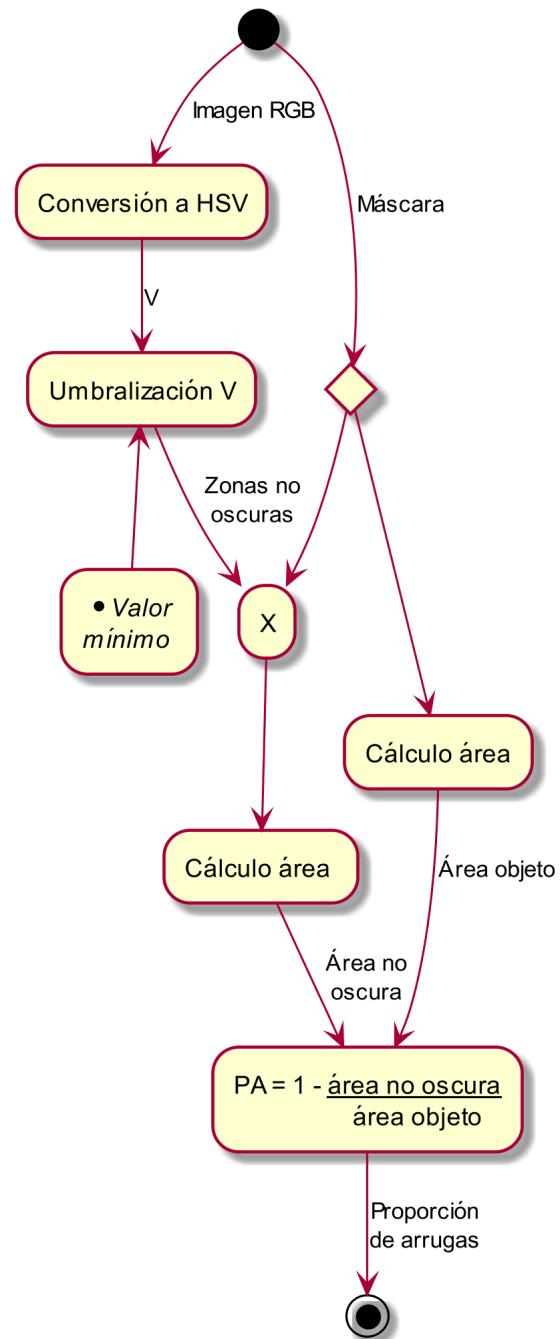
Este descriptor fue descartado porque es sensible a la iluminación y relativo al color de la almendra: umbrales buenos para almendras claras hacen que una almendra oscura lisa se considere totalmente arrugada.

El algoritmo es:

1. Se convierte la imagen RGB del objeto con iluminación frontal, al espacio HSV.
2. Se umbraliza el canal V según un valor mínimo, quedando una máscara de las zonas no oscuras.
3. Se multiplican binariamente la máscara de zonas no oscuras y la máscara del objeto.
4. Se calculan las áreas de cada máscara.
5. Se calcula la proporción de área oscura, estimador de la proporción de arrugas.

---

<sup>8</sup>Ver clase ClasificadorArrugas.m.



**Figura 4.13:** esquema del cálculo del descriptor 2 (proporción de arrugas en la almendra).

#### 4.3.4 Descriptor 3: relación de aspecto de caja envolvente

La relación de aspecto estimada es la proporción entre el lado menor y el lado mayor de la caja envolvente que contiene al objeto.<sup>9</sup> La métrica final es la media de las relaciones de aspecto del anverso y del reverso. La caja envolvente no es la mínima posible; en este trabajo usamos la caja envolvente horizontal calculada luego de horizontalizar la imagen según la orientación del eje mayor de una elipse ajustada al *blob*.

$$\text{relación de aspecto caja} = \frac{\text{lado menor caja}}{\text{lado mayor caja}} \quad (4.7)$$

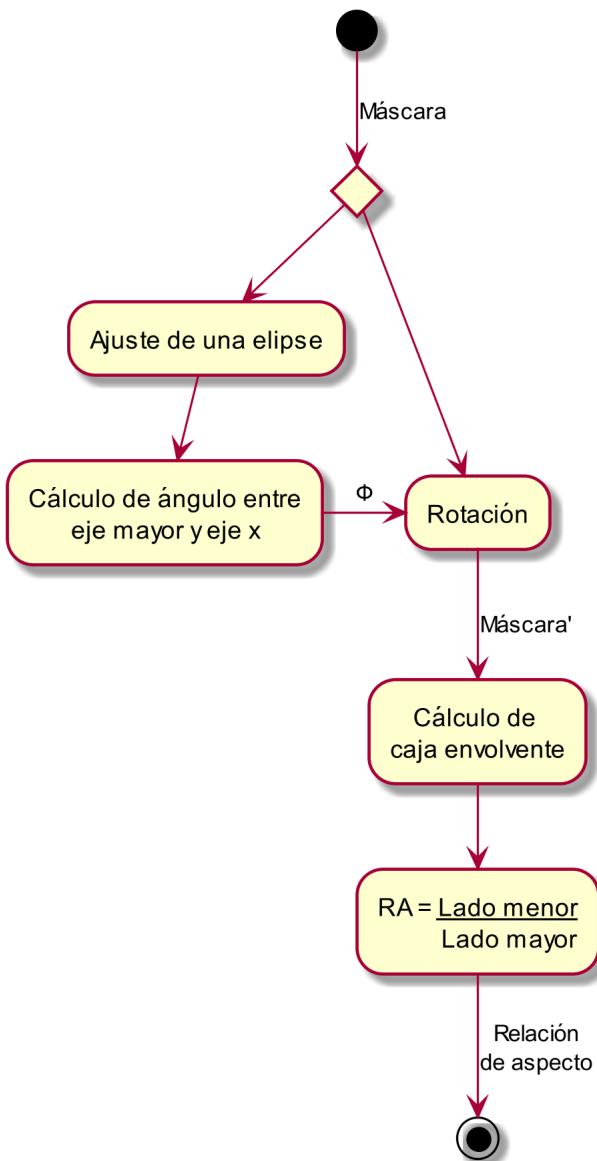
Determinamos valores mínimos y máximos para rechazar fragmentos, almendras deformadas o partidas, y objetos extraños.

El algoritmo consiste en:

1. Se ajusta una elipse al objeto.
2. Se horizontaliza la imagen, rotándola un ángulo igual (pero de signo opuesto) al descripto entre el eje mayor de la elipse y el eje *x*.
3. Se calcula la caja envolvente del objeto rotado.
4. Se calcula la relación de aspecto de la caja obtenida.

---

<sup>9</sup>Ver clase ClasificadorCajaRA.m.



**Figura 4.14:** esquema del cálculo del descriptor 3 (relación de aspecto de la caja envolvente horizontal).

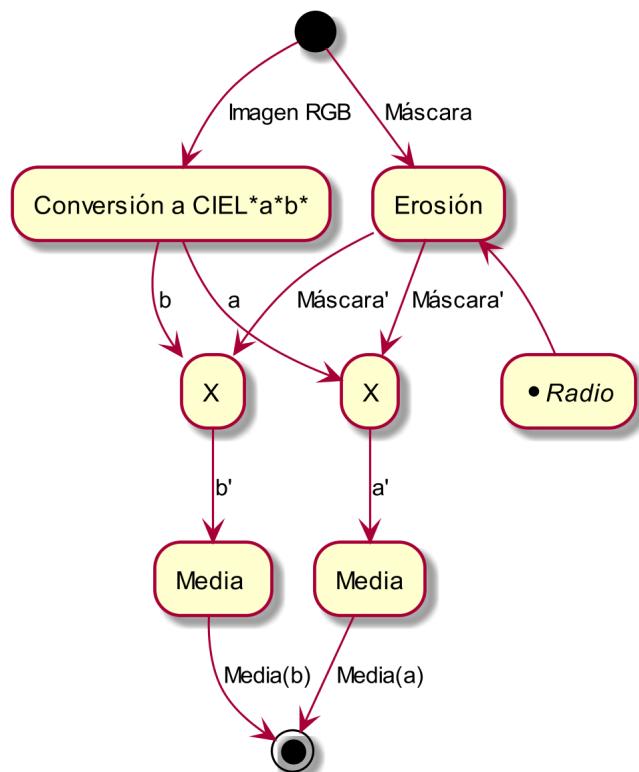
### 4.3.5 Descriptor 4: media de color en CIEL\*a\*b\* — componente a\*

La métrica es la media (de anverso y reverso) de la media de los valores del canal a\* de la imagen convertida al espacio CIEL\*a\*b\* 1976, con blanco de referencia D65.<sup>10</sup> Estos valores pueden analizarse en todo el objeto o sólamente en las zonas con tegumento, según la máscara que se use.

El descriptor fue pensado para descartar almendras con mal color u objetos que no son almendras. Establecemos entonces límites máximos y mínimos. Otro parámetro es el radio de un disco con el que se erosiona la máscara —sea completa o solo de área con tegumento—, ya que la información de color en los bordes no es buena (ver 3.5.3).

El algoritmo de cálculo es:

1. Se convierte la imagen RGB del objeto con iluminación frontal, al espacio CIEL\*a\*b\*.
2. Se erosiona la máscara del objeto.
3. Se aplica la máscara erosionada a los canales a\* y b\*.
4. Se calcula el valor medio de los valores de a\* y b\*.



**Figura 4.15:** esquema del cálculo de los descriptores 4 y 5 (medias de los componentes a\* y b\*).

<sup>10</sup>Ver clase ClasificadorCIELabMedia.m.

#### 4.3.6 Descriptor 5: media de color en CIEL\*a\*b\* — componente b\*

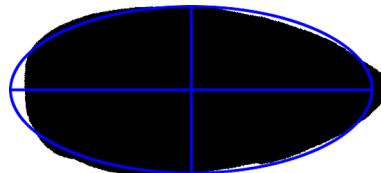
Análogo al descriptor 5, pero midiendo los valores de b\*. Evidenció menos poder de discriminación que a\*.

#### 4.3.7 Descriptor 6: relación de aspecto de elipse ajustada

El descriptor es la media de las relaciones de aspecto de elipses ajustadas (ver figura 4.16) a las máscaras de frente y dorso del objeto.<sup>11</sup> La relación de aspecto es el cociente entre el eje menor y el eje mayor de la elipse. Matlab estima la elipse a partir de los segundos momentos centrales de la imagen de máscara.

$$\text{relación de aspecto elipse} = \frac{\text{eje menor}}{\text{eje mayor}} \quad (4.8)$$

La relación de aspecto de la elipse ajustada es muy similar a la de la caja ajustada (descriptor 3, 4.3.4) para almendras buenas. En una proporción relevante del resto de los casos (almendras malas y no almendras), es menor a la relación de aspecto de la caja. De cualquier manera, ambas tienen el mismo poder de discriminación.



**Figura 4.16:** elipse ajustada a la máscara de una almendra.

El algoritmo es:

1. Se ajusta una elipse al objeto.
2. Se calcula la relación entre el eje menor de la elipse y el mayor.

<sup>11</sup>Ver clase ClasificadorElipseRA.m.



Ajuste de una elipse

Eje mayor  
Eje menor

$$RA = \frac{\text{Eje menor}}{\text{Eje mayor}}$$

Relación de aspecto



**Figura 4.17:** esquema del cálculo del descriptor 6 (relación de aspecto de una elipse ajustada).

#### 4.3.8 Descriptor 7: extensión de caja envolvente

El descriptor es la extensión de la caja envolvente (*bounding box*), siendo la extensión la relación entre el área de la máscara y el área de la caja.<sup>12</sup> Se mide solamente para una de las caras. La caja envolvente no es la mínima posible; en este trabajo usamos la caja envolvente horizontal calculada luego de horizontalizar la imagen según la orientación del eje mayor de una elipse ajustada al *blob*.

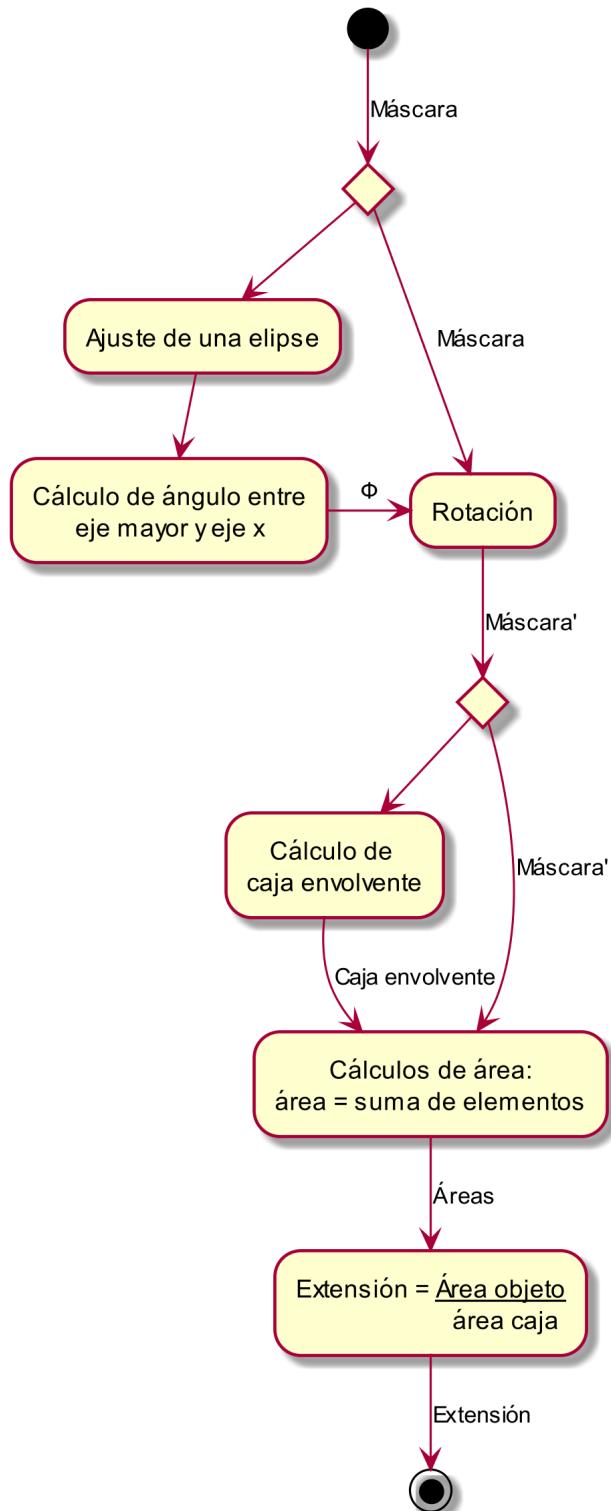
$$\text{extensión} = \frac{\text{área objeto}}{\text{área caja envolvente}} \quad (4.9)$$

Este descriptor busca eliminar objetos que tengan ramificaciones o que en general ocupen poco espacio de su caja envolvente. En función de esto, se definió como parámetro un límite mínimo del valor de extensión, pero no un máximo.

El algoritmo es:

1. Se ajusta una elipse al objeto.
2. Se horizontaliza la imagen, rotándola un ángulo igual (pero de signo opuesto) al descripto entre el eje mayor de la elipse y el eje *x*.
3. Se calcula la caja envolvente del objeto rotado.
4. Se calculan las áreas del objeto y de la caja envolvente.
5. Se calcula la extensión.

<sup>12</sup>Ver clase ClasificadorExtensionBB.m.



**Figura 4.18:** esquema del cálculo del descriptor 7 (extensión de la caja envolvente).

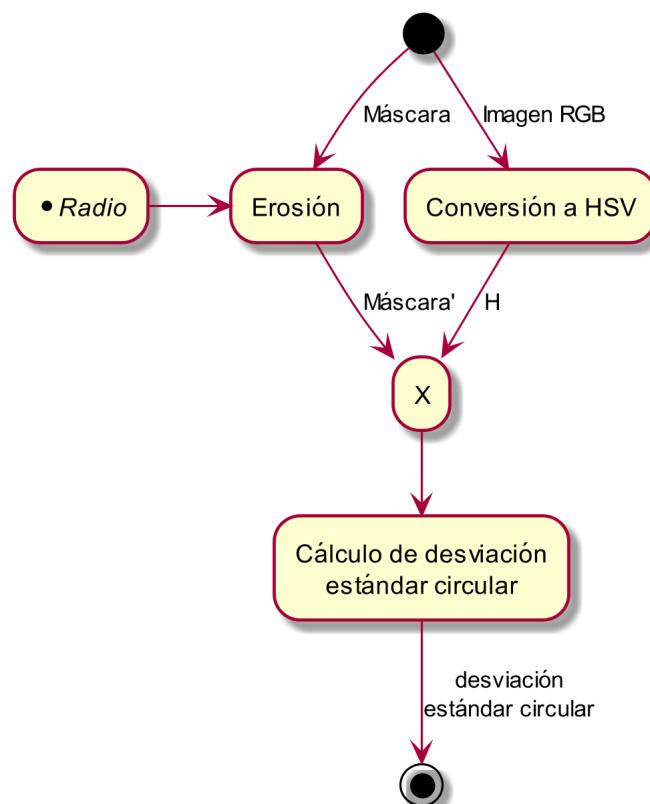
### 4.3.9 Descriptor 8: desviación estándar del color según el matiz

El descriptor es la desviación estándar circular de los valores del tono (canal H) de la almendra, ya sea con la máscara completa o solo en las zonas de tegumento.<sup>13</sup>

Este descriptor busca detectar manchas de color muy notorias. Se calculan las desviaciones para anverso y reverso; si cualquiera de las dos supera un valor límite (parámetro variable), se considera que el objeto es una almendra mala. Otro parámetro es el radio de un disco con el que se erosiona la máscara —sea completa o solo de área con tegumento—, ya que la información de color en los bordes no es buena (ver 3.5.3).

El algoritmo completo es:

1. Se convierte la imagen RGB con iluminación frontal a HSV.
2. Se erosiona la máscara del objeto.
3. Se aplica la máscara erosionada sobre el canal H.
4. Se calcula la desviación estándar circular de los valores de H.



**Figura 4.19:** esquema del cálculo del descriptor 8 (desviación estándar del color según el canal H).

<sup>13</sup>Ver clase ClasificadorHueDesviacion.m.

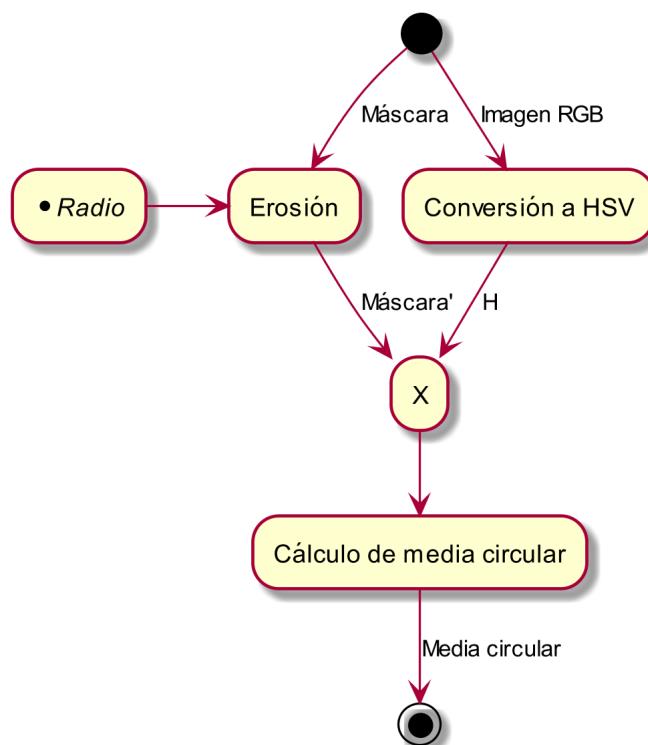
### 4.3.10 Descriptor 9: media del color según el matiz

El descriptor es la media circular de los valores del tono (canal H) de la almendra, ya sea en el objeto completo o solo en las zonas de tegumento.<sup>14</sup> La métrica final es la media de las medias calculadas en el anverso y en el reverso del objeto.

Este descriptor fue pensado para descartar almendra de color malo u objetos que no son almendras. Establecemos entonces límites máximos y mínimos. Otro parámetro es el radio de un disco con el que se erosiona la máscara —sea completa o solo de área con tegumento—, ya que la información de color en los bordes no es buena (ver 3.5.3).

El algoritmo es:

1. Se convierte la imagen RGB con iluminación frontal a HSV.
2. Se erosiona la máscara del objeto.
3. Se aplica la máscara erosionada sobre el canal H.
4. Se calcula la media circular de los valores de H.



**Figura 4.20:** esquema del cálculo del descriptor 9 (media del color según el canal H).

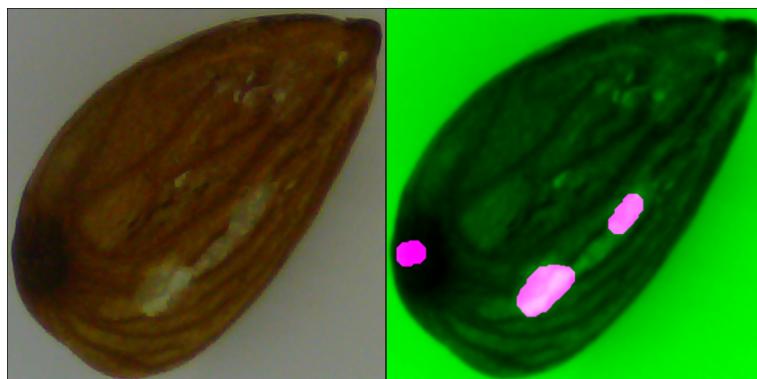
<sup>14</sup>Ver clase ClasificadorHueMedia.m.

### 4.3.11 Descriptor 10: área sin tegumento según canal S

Estimamos el área total de raspaduras (zonas sin tegumento en las que se ve la carne) a partir de las zonas que tienen valores bajos de saturación.<sup>15</sup> La métrica final es el área total, sumada en anverso y reverso.

Los parámetros variables son: el umbral de S —valor mínimo para que un píxel sea considerado tegumento—; el factor de escala para convertir a  $\text{mm}^2$ ; el radio de un disco que erosiona la máscara inicial, para no contemplar los bordes (ver 3.5.3); el radio de un disco con el que se realiza la operación de apertura, para extender el área medida; y el valor máximo tolerado.

Este algoritmo detecta muy bien aquellas zonas que tienen raspaduras superficiales, pero también incluye zonas muy oscuras de tegumento —normalmente puntos negros que se encuentran en la base de la almendra—. Como salida complementaria, el clasificador que calcula este descriptor también genera una máscara de las zonas con tegumento; esta puede utilizarse en los descriptores que miden color.

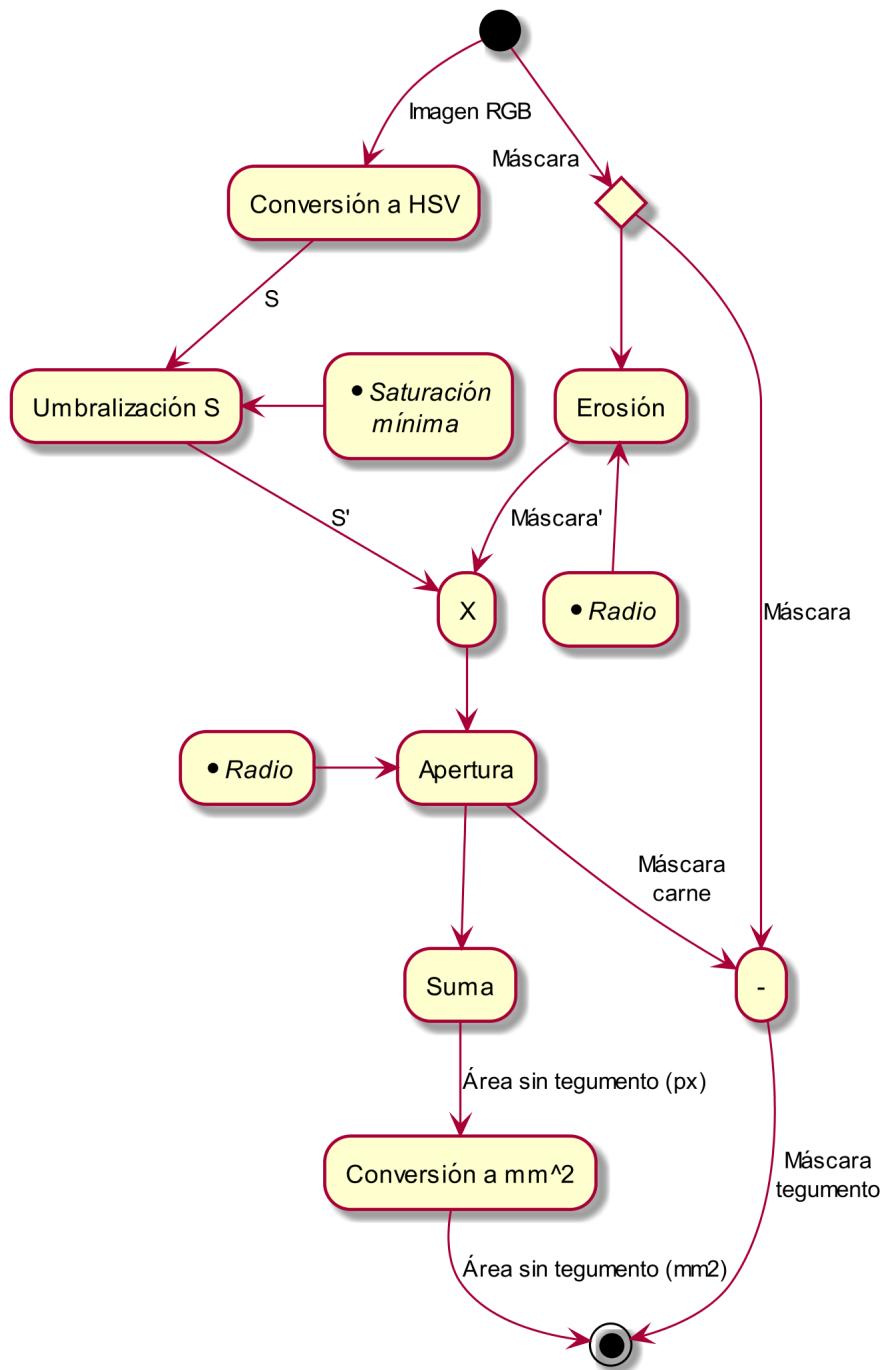


**Figura 4.21:** ejemplo de medición del descriptor 10 (área sin tegumento según canal S). Las zonas sin tegumento detectadas están marcadas en magenta.

El algoritmo es:

1. Se convierte la imagen RGB con iluminación frontal a HSV.
2. Se crea una máscara a partir del canal S, según umbrales mínimos y máximos de saturación.
3. Se erosiona la máscara del objeto.
4. Se multiplican binariamente las máscaras de S la del objeto erosionada.
5. Se aplica la operación de apertura morfológica con un disco como elemento estructurante. La máscara resultante es la máscara de las zonas de carne o hueso.
6. La máscara de tegumento es la diferencia binaria entre la máscara del objeto y la máscara de carne.
7. Se calcula el área total de carne, contando la cantidad de píxeles de la máscara.
8. Se escala el área en píxeles a  $\text{mm}^2$ .

<sup>15</sup>Ver clase ClasificadorRaspaduras.m.



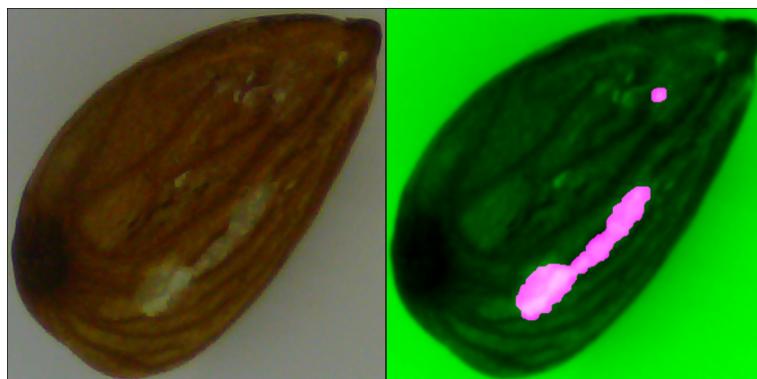
**Figura 4.22:** esquema del cálculo del descriptor 10 (área sin tegumento según el canal S).

### 4.3.12 Descriptor 11: área sin tegumento según canales H, S y V

Se estima el área total de raspaduras a partir de las zonas que se encuentran en ciertos rangos de valores en los canales H, S y V del espacio HSV.<sup>16</sup> La métrica final es el área total, sumada en anverso y reverso.

Los parámetros variables son: umbrales máximos y mínimos para H, S y V; el factor de escala para convertir a  $\text{mm}^2$ ; el radio de un disco que erosiona la máscara inicial, para no contemplar los bordes (ver 3.5.3); el radio un disco con el que se realiza la operación de apertura, para extender el área medida; y el valor máximo tolerado.

Este descriptor es mejor que el anterior (descriptor 10, 4.3.11) ya que no incluye dentro de las áreas a aquellas zonas de tegumento oscuro. Como salida complementaria, el clasificador que calcula este descriptor también genera una máscara de las zonas con tegumento; esta puede utilizarse en los descriptores que miden color.

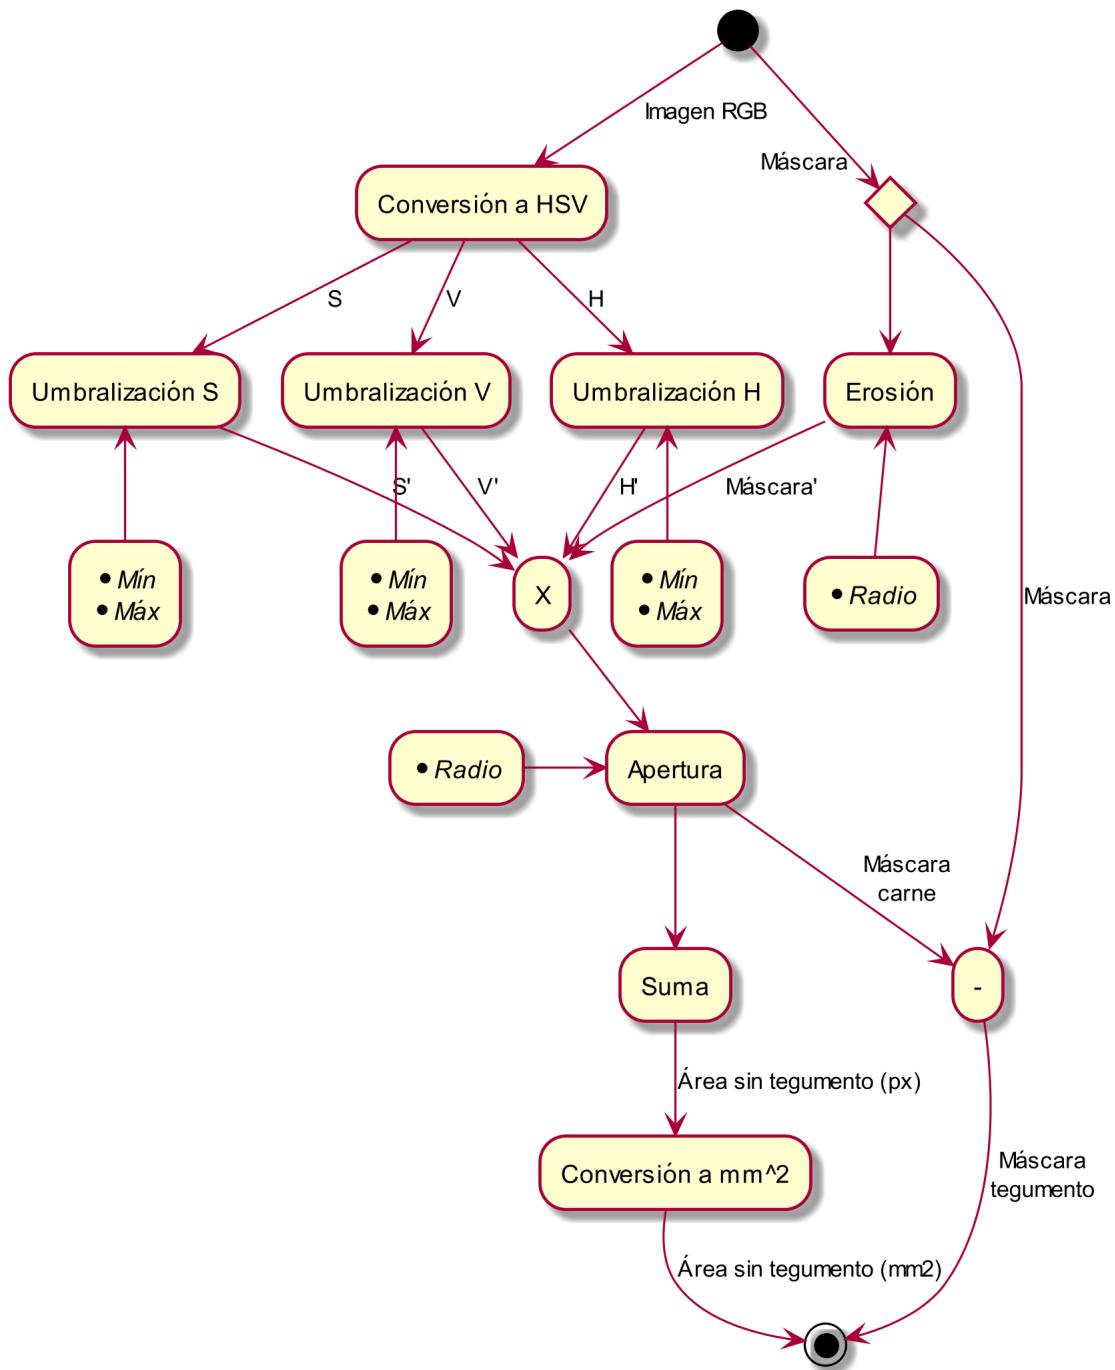


**Figura 4.23:** ejemplo de medición del descriptor 11 (área sin tegumento según canales H, S y V). Las zonas sin tegumento detectadas están marcadas en magenta.

El algoritmo consiste en:

1. Se convierte la imagen RGB con iluminación frontal a HSV.
2. Se crean máscaras a partir de los canales H, S y V, según umbrales mínimos y máximos para cada canal.
3. Se erosiona la máscara del objeto.
4. Se multiplican binariamente las máscaras de H, S, V y la del objeto erosionada.
5. Se aplica la operación de apertura morfológica con un disco como elemento estructurante. La máscara resultante es la máscara de las zonas de carne o hueso.
6. La máscara de tegumento es la diferencia binaria entre la máscara del objeto y la máscara de carne.
7. Se calcula el área total de carne, contando la cantidad de píxeles de la máscara.
8. Se escala el área en píxeles a  $\text{mm}^2$ .

<sup>16</sup>Ver clase ClasificadorRaspaduras2.m.



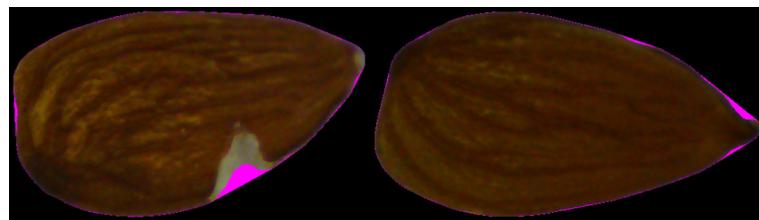
**Figura 4.24:** esquema del cálculo del descriptor 11 (área sin tegumento según los canales H, S y V).

### 4.3.13 Descriptor 12: solidez

El descriptor calculado es la solidez del objeto, la cual se define como la relación entre el área del objeto y el área de su envolvente convexa (*convex hull*).<sup>17</sup> La métrica final es la solidez mínima entre las calculadas para el frente y para el dorso del objeto.

$$\text{solidez} = \frac{\text{área objeto}}{\text{área envolvente convexa}} \quad (4.10)$$

Este descriptor apunta a detectar las almendras astilladas, que tienen concavidades localizadas. Sus parámetros variables son, entonces, valores de umbrales mínimos y máximos para considerar a una almendra como de Primera clase. En la práctica, sin embargo, detecta como falsos positivos a algunas almendras que tienen una protuberancia cilíndrica en el extremo opuesto a su base (ver figura 4.25). Esta protuberancia es una característica de la variedad de almendras utilizadas.

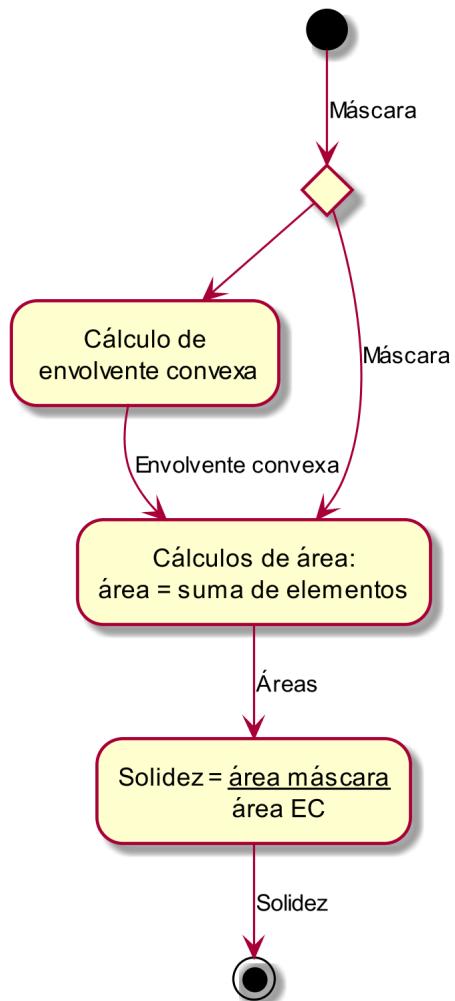


**Figura 4.25:** envolvente convexa de almendras. Izquierda: Una almendra trizada. Derecha: Una almendra en buen estado con una protuberancia en la punta, característica de esta variedad.

El algoritmo es:

1. Se calcula la envolvente convexa del objeto.
2. Se calculan las áreas de la envolvente convexa y del objeto. El área de una máscara es el recuento de los píxeles con valor 1 («verdadero»).
3. Se calcula la solidez.

<sup>17</sup>Ver clase ClasificadorSolidez.m.



**Figura 4.26:** esquema del cálculo del descriptor 12 (solidez).

## 5 Resultados

En base al desempeño observado durante el desarrollo y prueba de cada una de las etapas de preprocesamiento, segmentación y clasificación, elegimos algunas de ellas para formar parte del algoritmo a evaluar. El algoritmo es (ver figura 5.1):

1. Preprocesador: suavizado gaussiano
2. Segmentador: basado en imagen retroilumininada
3. Clasificador: según altura
4. Clasificador: según extensión de la caja envolvente
5. Clasificador: según relación de aspecto de los ejes de una elipse ajustada
6. Clasificador: según área sin tegumento (raspaduras) a partir de canales H, S y V
7. Clasificador: según media de color (canal H)
8. Clasificador: según desviación de color (canal H)
9. Clasificador: según media de color (canal a\*)
10. Clasificador: según media de color (canal b\*)
11. Clasificador: según solidez

Quedó fuera el clasificador según la relación de aspecto de la caja envolvente, porque es muy similar al de la relación de aspecto de la elipse ajustada. No se usó el clasificador según el área de arrugas por su mal desempeño general. El clasificador según área de raspaduras a partir de los canales H, S y V es mejor que el que solo usa S.

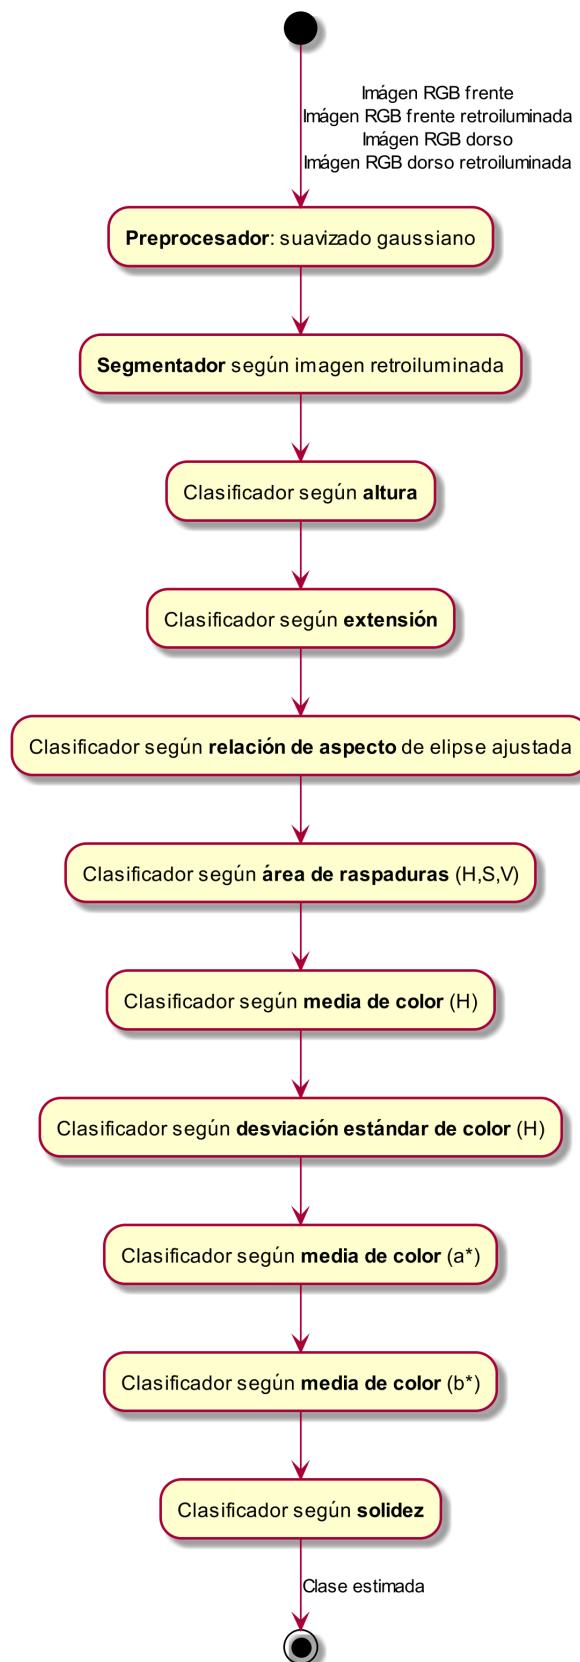
Es importante notar que los clasificadores según características de color (etapas 7, 8, 9 and 10) realizan sus medidas a partir de los datos que están en las zonas con tegumento<sup>1</sup>; esta está determinada por la máscara creada por el clasificador según raspaduras y por tanto las medidas solo serán correctas en el caso de almendras y objetos de colores similares a los de las almendras.

Los parámetros de funcionamiento de cada clasificador fueron ajustados heurísticamente durante su desarrollo<sup>2</sup>, analizando su desempeño general o específico para el defecto que buscaban encontrar. Los parámetros que determinan los límites de clasificación se ajustarán según diferentes estrategias, como se menciona más adelante.

---

<sup>1</sup>También se pueden usar con la máscara del objeto completo.

<sup>2</sup>Los valores se pueden ver en los archivos de clase correspondientes o en cualquier archivo `parametros_efectivos*.yml` en las carpetas de experimentos.



**Figura 5.1:** etapas del algoritmo final.

## 5.1 Metodología de ajuste y evaluación

### 5.1.1 Evaluación

La evaluación se hará sobre el conjunto set3, para dos casos de trabajo distintos:

1. Contemplando las tres clases del conjunto: Primera, Mala y No Almendra.
2. Simplificando a solo dos clases: Buena (clase Primera) y Mala (clase Mala y clase No Almendra). Esto se justifica porque no encontramos criterios confiables para separar las clases Mala y No Almendra.

La evaluación se hará sobre el conjunto de evaluación —un 20 % del total—, mientras que el ajuste de los parámetros de clasificación de cada etapa se hará según los valores de los descriptores sobre el conjunto de entrenamiento —el restante 80 %—. Ver 3.6.

Los resultados de nuestro clasificador serán contrastados contra los obtenidos por algoritmos de aprendizaje automático en KNIME y Matlab Classification Learner (ver 2.6) a partir de los mismos descriptores. De la herramienta de Matlab se usarán algunas de las configuraciones por defecto disponibles en la galería de clasificadores (usando validación cruzada con las mismas proporciones —80 % de entrenamiento y 20 % de validación— que usamos para dividir el conjunto set3):

- Un árbol de decisiones simple, con menos de cuatro particiones (*splits*)
- Un árbol de decisiones de tamaño medio, con menos de veinte particiones (*splits*)
- Una máquina de vector soporte o máquina de soporte vectorial (SVM) lineal
- Una SVM de núcleo cuadrático
- Una SVM de núcleo cúbico
- Un clasificador de k vecinos cercanos (*k-nearest neighbours*, KNN), con un vecino
- Un clasificador KNN con diez vecinos
- *Boosted Trees*: un arreglo de clasificadores (árboles de decisión) optimizados con el algoritmo Adaboost.

En KNIME dividimos el conjunto set3 en dos subconjuntos (80 % de entrenamiento y 20 % de validación) y probamos dos clasificadores, con las opciones por defecto:

- Un árbol de decisión con menos de diez particiones
- Un clasificador KNN con tres vecinos

### 5.1.2 Métrica

La métrica de evaluación de cada algoritmo será la exactitud global (*overall accuracy*) del sistema:

$$\text{Exactitud global} = \frac{\text{elementos clasificados correctamente}}{\text{total de elementos}} \quad (5.1)$$

Esta se puede usar tanto para el caso de clasificación multiclase (Primera, Mala y No Almendra) como para la simplificación binaria (Buena y Mala).

Para este último caso, las proporciones de Buena y Mala son muy similares y por tanto no existe error de (alta) exactitud causado por clases desproporcionadas. Dado esto, un clasificador binario aleatorio tendrá una exactitud igual a la proporción inicial de las clases, cercana al 50 %; por tanto 50 % es la base de referencia para la clasificación binaria.

### 5.1.3 Ajuste

Los parámetros de clasificación (máximos y mínimos tolerados) de cada etapa clasificadora fueron ajustados siguiendo distintas estrategias, en base a los valores de los descriptores calculados para las almendras clasificadas como de Primera clase dentro del conjunto de entrenamiento (ver tabla 5.1).

Las estrategias son:

**Máximos y mínimos (Maxmin)** Los máximos y mínimos de tolerancia para cada clasificador son los máximos y mínimos medidos en las almendras de Primera clase del conjunto de entrenamiento.

**90 %** Se supone que cada descriptor sigue una distribución normal, con media  $\mu$  y desviación estándar  $\sigma$ ; la muestra es el conjunto almendras de Primera clase dentro del conjunto de entrenamiento. Se ajustan los máximos a  $\mu + 1,64\sigma$  y los mínimos a  $\mu - 1,64\sigma$ , lo cual abarca el 90 % de los datos en una distribución normal.

**95 %** Análoga a la estrategia anterior, pero con un rango  $[\mu - 2\sigma, \mu + 2\sigma]$ , que abarca al 95 % de los datos en una distribución normal.

**99 %** Análoga a las anteriores, pero con un rango  $[\mu - 2,6\sigma, \mu + 2,6\sigma]$ , que abarca al 99 % de los datos en una distribución normal.

**Heurística 1 (H1)** Todos los límites igual a los de **95 %**, menos la tolerancia del área máxima de raspaduras; esta es la que determina la norma de UNECE: el área de un círculo de 3 mm de diámetro (aproximadamente  $7 \text{ mm}^2$ ).

**Heurística 2 (H2)** Análoga a **Heurística 1** pero usando los límites de **99 %**.

**Tabla 5.1:** características de los valores de los descriptores para las almendras de clase Buena (Primera) del conjunto de entrenamiento.

Medidas	Descriptores								
	Altura [px]	Extensión [px <sup>2</sup> /px <sup>2</sup> ]	Relación de aspecto [px/px]	Área de raspaduras [mm <sup>2</sup> ]	Media de H [°]	Desv. Est. de H [°]	Media a*	Media b*	Solidez [px <sup>2</sup> /px <sup>2</sup> ]
<b>máximo</b>	583,50	0,774	0,643	6,81	34,48	10,48	17,48	30,72	0,9955
<b>mínimo</b>	428,50	0,727	0,444	0,00	21,53	3,52	5,13	6,47	0,9837
$\mu$	510,14	0,750	0,553	0,46	27,85	4,94	12,37	21,13	0,9931
$\sigma$	32,62	0,011	0,029	1,25	2,29	0,78	1,78	5,00	0,0014
$\mu + 1,64\sigma$	563,64	0,767	0,600	2,52	31,60	6,21	15,30	29,33	0,9953
$\mu - 1,64\sigma$	456,64	0,732	0,505	-1,59	24,10	3,66	9,45	12,94	0,9908
$\mu + 2\sigma$	575,38	0,771	0,610	2,97	32,42	6,49	15,94	31,13	0,9958
$\mu - 2\sigma$	444,90	0,729	0,495	-2,04	23,28	3,38	8,81	11,14	0,9903
$\mu + 2,6\sigma$	594,95	0,777	0,628	3,72	33,79	6,96	17,01	34,13	0,9966
$\mu - 2,6\sigma$	425,32	0,722	0,477	-2,79	21,91	2,91	7,74	8,14	0,9895

## 5.2 Resultados

La tabla 5.2 muestra los resultados obtenidos para las distintas estrategias de ajuste de parámetros, sobre los conjuntos de entrenamiento y de evaluación; la tabla 5.3 muestra los resultados obtenidos con los otros clasificadores.

**Tabla 5.2:** resultados obtenidos con distintas estrategias de ajuste de parámetros.

Clasificador	Exactitud global [%]			
	Entrenamiento		Evaluación	
	Buena, Mala	Primera, Mala, No Almendra	Buena, Mala	Primera, Mala, No Almendra
<b>Maxmin</b>	94,9	80,8	<b>92,9</b>	<b>82,7</b>
<b>90 %</b>	78,5	66,7	75,0	64,9
<b>95 %</b>	86,9	73,2	84,8	74,4
<b>99 %</b>	93,4	78,8	91,1	79,8
<b>H1</b>	89,2	74,6	86,6	75,6
<b>H2</b>	94,9	79,8	<b>92,9</b>	81,0

Hay una brecha de más de 10 % entre los resultados obtenidos considerando tres clases (Primera, Mala y No Almendra) y los obtenidos para el caso simplificado de dos clases (Buena y Mala). Esto era esperable, ya que nuestras etapas trabajan de forma independiente, y cada clasificador distingue entre dos clases solamente.

Los peores resultados son los de la estrategia **90 %**. Esto da un indicio de que (en general y suponiendo distribuciones normales) es pequeña la intersección entre los conjuntos de valores

**Tabla 5.3:** resultados obtenidos con otros clasificadores.

Exactitud global [ % ]			
	Clasificador	Buena, Mala	Primera, Mala, No Almendra
Matlab  Classification Learner	Árbol simple	91,5	82,4
	Árbol medio	<b>94,1</b>	89,1
	SVM lineal	90,2	88,5
	SVM cuadrática	91,1	90,4
	SVM cúbica	93,1	<b>92,2</b>
	KNN 1 vecino	93,8	89,7
	KNN 10 vecinos	89,2	86,5
KNIME	Boosted Trees	<b>94,5</b>	91,5
	KNN 3 vecinos	<b>94,7</b>	90,3
	Árbol medio	92	<b>92,9</b>

correspondientes a Buenas y Malas. Dicho de otra manera, los descriptores elegidos tienen un buen poder de discriminación.

Nuestros mejores resultados corresponden a las estrategia **H2** y **Maxmin**, con una exactitud de 92,9 % para el caso de dos clases. Las tablas 5.4a y 5.4b muestran sus matrices de confusión para el conjunto de evaluación. Una distribución similar se observó sobre los conjuntos de entrenamiento, con **H2** teniendo menos Malas clasificadas como Buenas pero más Buenas clasificadas como Malas.

**Tablas 5.4:** matrices de confusión para el caso de dos clases, en el conjunto de evaluación.

		Clase estimada				Clase estimada	
		Buena	Mala			Buena	Mala
Clase real	Buena	50	5	Clase real	Buena	48	7
	Mala	3	54		Mala	1	56

Las Malas que se clasificaron como Buenas estaban clasificadas como Malas por tener mal color y estar arrugadas; por estar sucias; y por estar raspadas y astilladas, respectivamente.

Las Buenas que se clasificaron como Malas fueron rechazadas por su media de color (H y CIEL\*a\*b\*), extensión, solidez o relación de aspecto.

Los resultados de contraste obtenidos en KNIME y Matlab Classification Learner tienen una brecha menor entre el caso de tres clases y el caso simplificado a dos clases; además, las exactitudes de las clasificaciones multiclase son mayores a las logradas con nuestro clasificador. Esto es entendible porque todos los otros clasificadores probados contemplan relaciones complejas entre los descriptores, en lugar de hacer un análisis independiente para cada descriptor.

La diferencia entre las mejores estrategias de ajuste (**H2** y **Maxmin** con 92,9 % sobre el conjunto de validación) y los mejores clasificadores externos es menor a 2 %. Asumiendo que los clasificadores

más potentes (como *Boosted Trees*) son aptos para ser aplicados a este problema y que deberían obtener los resultados máximos posibles, podemos decir que:

- nuestra estrategia de clasificación es buena, ya que alcanza exactitudes cercanas a las de otros clasificadores más complejos;
- los descriptores elegidos pueden ser insuficientes para lograr una clasificación con una exactitud del 100 %;
- la verdad de referencia (la clasificación manual del conjunto) puede tener errores que impiden una clasificación con una exactitud del 100 %.

## 6 Conclusiones

### 6.1 Revisión

Se construyó una estructura fácilmente modificable en la que se probaron prototipos de sistemas de visión que podrían existir en una máquina clasificadora óptica de almendras peladas. Las pruebas con espejos no dieron buenos resultados. Las mejores imágenes y más fáciles de segmentar son las que se obtuvieron con iluminación frontal y retroiluminación subsiguiente.

Con el sistema de visión compuesto por cámara, iluminación frontal y retroiluminación, se creó un conjunto de imágenes correspondientes al anverso y reverso de 564 objetos que típicamente se pueden encontrar en una línea de procesamiento de almendras. El conjunto de imágenes fue etiquetado manualmente según reglas basadas en la norma de comercio de almendras de UNECE, y también fue dividido en subconjuntos de entrenamiento y de evaluación.

Se diseñó e implementó en Matlab un sistema modular de clasificación. Se crearon módulos de preprocessamiento, segmentación y clasificación. Estos últimos usaron descriptores de color y forma. La mayoría de los descriptores son básicos y conocidos en la literatura; a algunos otros los pensamos específicamente para esta aplicación.

Se probó el sistema clasificador sobre el conjunto de imágenes generado. Se ajustaron los umbrales de clasificación con distintas estrategias, usando los valores de los descriptores medidos sobre el conjunto de entrenamiento. Se contrastaron con los resultados obtenidos usando otros clasificadores típicos con los mismos descriptores.

Usamos la exactitud global (*overall accuracy*) como métrica de desempeño. Considerando un problema de clasificación binaria (almendras buenas vs. otros), nuestro clasificador obtuvo resultados cercanos a los de otros clasificadores, con una exactitud de 92,7 %.

Si el problema es de clasificación multiclase (almendras de primera clase vs. almendras malas vs. no almendras), nuestro clasificador tiene un desempeño 10 % por debajo del de otros que alcanzaron un 93 %.

## 6.2 Discusión y trabajos futuros posibles

### 6.2.1 Sistema de visión

Deberían determinarse y construirse posibles sistemas de movimiento y transporte para poder tener más especificaciones o límites de diseño del sistema de visión. El sistema con retroiluminación es bueno para elaborar conjuntos de imágenes que sirvan para el desarrollo de los programas, pero difícilmente sea el óptimo para una máquina.

La cámara utilizada es lenta. Podría utilizarse una mejor en conjunto con una lente que permita enfocar los objetos de interés. La lente permitiría distancias de trabajo más seguras para la cámara; nuestro prototipo final tiene la cámara a 6 cm de la superficie, lo que puede ser poco espacio para los sistemas de movimiento y rechazo.

### 6.2.2 Conjuntos de imágenes

El conjunto de imágenes construido no es suficientemente descriptivo ni grande, y la clasificación manual tiene errores causados por criterios difusos y por el hecho de haber clasificado a partir de imágenes de los objetos y no los objetos en sí. Es necesario contar con un conjunto mayor de muestras de almendras con defectos —particularmente con los defectos menos habituales—, y etiquetarlas con ayuda de productores y operarios, siguiendo criterios claramente definidos.

### 6.2.3 Evaluación

Usamos la exactitud global como métrica de evaluación porque es simple, pero esta no está exenta de error y su interpretación depende de las características del problema. Hay muchas otras métricas de evaluación que pueden, en conjunto, describir mejor el desempeño del clasificador sobre este problema. Es importante saber cuáles y cómo usarlas para poder hacer una buena optimización.

### 6.2.4 Descriptores

No hemos analizado el poder discriminador de los descriptores usados, y es posible que alguno sea totalmente inútil o redundante. No hemos analizado tampoco la robustez de los descriptores que usan información de color, y todo indica que los valores ajustados para el conjunto de imágenes set3 no servirán para otras imágenes que se obtengan con otras condiciones de iluminación o cámara. Si bien se pueden reajustar los parámetros de cada etapa clasificadora, sería muy conveniente lograr independencia de esas condiciones ambientales, ya sea trabajando en espacios normalizados de color o haciendo medidas relativas (por ejemplo, relativas al blanco del fondo). La última opción es proveer al usuario de procedimientos simples de calibración global. Los descriptores geométricos, por otro lado, son robustos e invariantes respecto a la orientación.

Hay muchas almendras que se pueden considerar malas por exceso o carencia de arrugas. Más allá del impacto estético, el exceso de arrugas indica una almendra deshidratada, seca o achicharrada, con poca carne; mientras que la carencia de arrugas puede sugerir daño de insectos. En este trabajo las arrugas se han discriminado implícitamente con los descriptores de color, pero podrían estar mejor representadas con descriptores de textura.

Las imágenes de almendras completas del conjunto set3 son de aproximadamente  $300\text{ px} \times 500\text{ px}$ , un tamaño grande para muchos de los descriptores. Sería conveniente contar con versiones escaladas de cada imagen, y usar las de mayor tamaño solo en aquellos caso en que sea estrictamente necesario. De otra manera, los tiempos de cálculo crecen innecesariamente.

Los resultados máximos de 94 % sugieren que se necesitan más descriptores para caracterizar las imágenes. Una posible forma rápida de probar más cosas es mediante la caja de herramientas Balu de Domingo Mery, que permite fácilmente ejecutar y evaluar funciones de segmentación, extracción de descriptores y clasificación de conjuntos de imágenes. [19] Una rápida prueba con 123 descriptores geométricos y de color<sup>1</sup> (también se pueden agregar descriptores de textura) y un clasificador tipo *Boosted Trees*, alcanzó una exactitud de casi 96 % sobre un conjunto de evaluación de 20 % y usando dos clases. Por supuesto, el caso merece análisis del poder discriminador de cada descriptor para reducir la dimensionalidad del sistema.

### 6.2.5 Clasificador

La clasificación en solo dos clases (almendras buenas vs. otros) simplifica de gran manera el desarrollo de un buen sistema, ya que en muchos casos es difícil separar los trozos de almendras de otros objetos extraños, e incluso es difícil saber si un trozo de almendra perteneció a una almendra en buen estado general o no. Pienso entonces que hoy sería prudente enfocarse en lograr un buen clasificador binario que pueda integrarse a la máquina completa. Con todo lo que se aprenda en esa iteración se podrá abordar el desafío de un clasificador que separe el producto en más clases.

En cuanto a la estructura del clasificador implementado (tipo árbol de una rama y modular), esta fue pensada contemplando una posible necesidad de los usuarios de modificar en línea las tolerancias de cada factor analizado, para obtener rendimientos mayores a costa de una menor calidad total. Este requerimiento limita el espectro de clasificadores a usar, ya que requiere de relaciones simples o independencia entre los descriptores.

Un mejor enfoque sería calcular varios clasificadores estándar —de mayor o menor complejidad y ajustados para diferentes niveles de exactitud—, y que luego el usuario pueda elegir el que quiera según la calidad que deseé. Para un clasificador binario, esto implica moverse sobre la curva Característica Operativa del Receptor (*ROC curve*), que describe la relación de compromiso entre tasa de aciertos y tasa de falsos positivos. Para este fin, en la actualidad existen muchas herramientas de aprendizaje automático o *machine learning* que permiten optimizar clasificadores de forma rápida y contemplando una cantidad enorme de descriptores. Por supuesto, todos los descriptores que se usen en el clasificador deberán ser luego calculados en línea para cada objeto, con el tiempo que eso significa. En cualquier caso, las herramientas desarrolladas en este trabajo pueden resultar útiles para el desarrollo y evaluación de nuevos descriptores.

---

<sup>1</sup>Ver en [/experimentos/balu/](#).

## Referencias

- [1] Pablo Daniel Aguado y col. *Una estrategia para la clasificación óptica de almendras. (dataset)*. Ver. 1.0. San Juan, Argentina: Universidad Nacional de San Juan, 2017. doi: 10.5281/zenodo.838196 (Citado en páginas 1, 17)
- [2] Luis Iannamico. «Frutos secos: evolución del mercado internacional y situación argentina». En: *Suplemento El Rural del Diario Río Negro* (abr. de 2015). URL: <http://inta.gob.ar/documentos/frutos-secos-evolucion-del-mercado-internacional-y-situacion-argentina> (Citado en página 2)
- [3] FAOSTAT, División de Estadística de la Organización de las Naciones Unidas para la Alimentación y la Agricultura. *Matriz detallada del comercio de almendras peladas*. <http://www.fao.org/faostat/es/#search/almendras>. [Internet; visitado en junio de 2017] (Citado en página 2)
- [4] Luis Iannamico. *Cultivo del almendro*. Ed. por Ediciones INTA. 2015 (Citado en página 2)
- [5] Humberto Secchi y Francisco Rossomando. *Diseño e implementación de una estrategia de clasificación óptica de almendras para pequeños productores*. PTDS N° 80020150600004SJ. 2016 (Citado en página 3)
- [7] Secretaría de Agricultura y Ganadería de la República Argentina. *Resolución 1352*. Buenos Aires, 14 de nov. de 1967. URL: <http://servicios.infoleg.gob.ar/infolegInternet/anexos/155000-159999/157438/norma.htm> (Citado en página 4)
- [8] United States Department of Agriculture. *United States Standards for Grades of Shelled Almonds*. Mar. de 1997 (Citado en página 4)
- [9] United Nations. *UNECE standard DDP-06 concerning the marketing and commercial quality control of almond kernels*. New York y Geneva, 2003 (Citado en página 4)
- [10] *Código alimentario argentino. Capítulo XI: alimentos vegetales*. Artículo 895 - (Resolución Conjunta SPReI N° 169/2013 y SAGyP N° 230/2013) (Citado en página 4)
- [23] Rafael C. Gonzalez y Richard E. Woods. *Digital Image Processing*. Ed. por Pearson Education Inc. 3.<sup>a</sup> ed. Dorlinkg Kidersley India Pvt. Ltd, 2014. Cap. 10. ISBN: 978-93-325-1846-9 (Citado en página 28)
- [24] Nobuyuki Otsu. «A threshold selection method from gray-level histograms». En: *IEEE transactions on systems, man, and cybernetics* 9.1 (1979), págs. 62-66 (Citado en página 30)
- [27] Nima Teimouri y col. «An Artificial Neural Network-Based Method to Identify Five Classes of Almond According to Visual Features». En: *Journal of Food Process Engineering* 39.6 (2016), págs. 625-635. ISSN: 1745-4530. doi: 10.1111/jfpe.12255. URL: <http://dx.doi.org/10.1111/jfpe.12255> (Citado en página 35)
- [31] NCSS, LLC. *NCSS 11 Statistical Software (User Manual)*. Kaysville, Utah, USA, 2016. Cap. 230: Circular Data Analysis. URL: <https://www.ncss.com/software/ncss-documentation/#DescriptiveStatistics> (Citado en página 39)

- [32] Juan Pablo Graffigna Vaggione. «Detección de defectos de superficie mediante técnicas de Visión Artificial: aplicación a la selección de aceitunas». Trabajo Final. San Juan, Argentina: Universidad Nacional de San Juan, 1996

## Programas

- [15] The Mathworks Inc. *Matlab*. Ver. R2015b. 20 de ago. de 2015. URL: <https://www.mathworks.com/products/matlab.html> (Citado en página 7)
- [16] Jiri Cigler y col. *YAMLMatlab*. Commit 20d3e1f. 2017. URL: <https://github.com/aguadopd/yamlmatlab> (Citado en página 7)
- [17] David Varga. *MBeautifier*. Ver. 1.2.1. 18 de nov. de 2016. URL: <https://github.com/davidvarga/MBeautifier> (Citado en página 7)
- [18] Eduard Polityko. *Confusion Matrix and its Derivations*. Ver. 1.0. 1 de mar. de 2017. URL: <https://www.mathworks.com/matlabcentral/fileexchange/61817-confusion-matrix-and-its-derivations> (Citado en página 7)
- [19] Domingo Mery. *BALU: A Matlab toolbox for computer vision, pattern recognition and image processing*. Ver. 4.0.1. 22 de mar. de 2016. URL: <http://dmery.ing.puc.cl/index.php/balu> (Citado en páginas 7, 67)
- [20] The GIMP team. *GIMP*. Ver. 2.8.18. 16 de jul. de 2016. URL: <https://www.gimp.org> (Citado en página 7)
- [21] David Tschumperlé y GREYC UMR CNRS 6072, Image Team. *G'MIC (plug-in for GIMP)*. Ver. 1.7.8. 18 de nov. de 2016. URL: <http://gmic.eu> (Citado en página 7)
- [22] KNIME GmbH. *KNIME Analytics Platform*. Ver. 3.3.2. 6 de abr. de 2017. URL: <https://www.knime.org> (Citado en página 7)

## Créditos de imágenes

- [6] Jack Kelly Clark. *Cross section of an almost mature almond nut*. Ed. por University of California. <http://fruitsandnuts.ucdavis.edu/files/108928display.jpg>. 2000. URL: <http://fruitsandnuts.ucdavis.edu/pages/almond/> (Citado en página 3)
- [11] Tomra Sorting Food Americas. *Nimbus working principle*. URL: <https://www.tomra.com/en/solutions-and-products/sorting-solutions/food/sorting-equipment/nimbus/> (Citado en página 5)
- [12] Bühler AG. *Unblanched Almonds*. URL: <http://www.buhlergroup.com/global/en/process-technologies/optical-sorting/nut-sorting/almond-sorting.htm> (Citado en página 5)
- [13] Bühler Sortex Inc. *Nuts and Dried Fruit Optical Sorting (Brochure)*. 2015 (Citado en página 6)
- [14] Tomra Sorting Food Americas. *Nimbus Optical Sorter (Brochure)*. 2016 (Citado en página 6)

- [25] Stéfan van der Walt y col. «scikit-image: image processing in Python». En: *PeerJ* 2 (jun. de 2014), e453. ISSN: 2167-8359. DOI: 10.7717/peerj.453. URL: [http://scikit-image.org/docs/stable/auto\\_examples/xx\\_applications/plot\\_thresholding.html](http://scikit-image.org/docs/stable/auto_examples/xx_applications/plot_thresholding.html) (Citado en página 30)
- [26] Torben Trindkaer Nielsen. *An Implementation Of The Connected Component Labelling Algorithm*. 1 de oct. de 2014. URL: <https://www.codeproject.com/Articles/825200/An-Implementation-Of-The-Connected-Component-Label> (Citado en página 30)
- [28] Usuarios de Wikimedia Commons: Maksim, Pbroks3. *File:ConvexHull.svg*. Ed. por Wikimedia Commons. 2008. URL: <https://commons.wikimedia.org/wiki/File:ConvexHull.svg> (Citado en página 38)
- [29] Usuario de Wikimedia Commons: Jespa. *File:Simple concave polygon Convex Hull.svg*. Ed. por Wikimedia Commons. CC BY-SA 4.0. 2017. URL: [https://commons.wikimedia.org/wiki/File:Simple\\_concave\\_polygon\\_Convex\\_Hull.svg](https://commons.wikimedia.org/wiki/File:Simple_concave_polygon_Convex_Hull.svg) (Citado en página 38)
- [30] Usuario de Wikimedia Commons: SharkD. *File:HSV color solid cylinder alpha lowgamma.png*. Ed. por Wikimedia Commons. CC BY-SA 3.0, GFDL. 2017. URL: [https://commons.wikimedia.org/wiki/File:HSV\\_color\\_solid\\_cylinder\\_alpha\\_lowgamma.png](https://commons.wikimedia.org/wiki/File:HSV_color_solid_cylinder_alpha_lowgamma.png) (Citado en página 38)

## A Organización de los archivos

- /inicializar.m – Archivo de inicialización (ver anexo B).
- /tfinal\_AGUADO.pdf – Este documento.
- /clases/ – Archivos de clase de preprocesadores, segmentadores, clasificadores, clases principales, enumeraciones y otros.
- /experimentos/ – Archivos de cada experimento realizado. Cada carpeta contiene los archivos de configuración del experimento y planillas con los resultados generados.
- /funciones/ – Funciones principales y auxiliares desarrolladas en Matlab.
- /GUI/ – Interfaz gráfica de usuario.
- /imagenes/ – Los conjuntos de imágenes generados y sus metadatos. set1 sirvió para experimentación inicial, con set2 se desarrollaron los primeros algoritmos y set3 es el conjunto principal con el que se evaluó el sistema (ver sección 3.5). De este último se incluyen versiones preprocesadas —recortadas, sin distorsión y con máscaras binarias—. Los archivos .csv son las listas completas de imágenes y de los conjuntos de entrenamiento y evaluación; la planilla .xlsx tiene información sobre la clasificación manual.
- /info/ – Documentos e imágenes que fueron útiles para la realización de este trabajo.
- /otros/ – Archivos correspondientes a programas de terceros requeridos o utilizados: Balu, YAMLMatlab y multic.
- /scripts/ – Programas auxiliares usados durante el trabajo. No son necesarios para la ejecución de experimentos; sirvan para referencia futura.

## B Uso de los programas

Los programas requieren que se definan las variables `carpeta_base` y `carpeta_imagenes` con las rutas **absolutas** a la carpeta raíz de los programas (raíz de las carpetas `GUI`, `clases`, ...) y a la carpeta raíz de las imágenes respectivamente (raíz de las carpetas `set1`, `set2`, `set3`, ...).

Para ello, como requisito inicial, se debe editar el archivo `inicializar.m`, disponible en el directorio raíz.

Si bien se pueden editar y ejecutar los experimentos disponibles en la carpeta `/experimentos/`, recomiendo ejecutar la interfaz gráfica de usuario para poder apreciar lo que están haciendo los programas. Para ello:

1. Editar y ejecutar `inicializar.m`.
2. Editar `/GUI/gui.m` y seleccionar (comentando y descomentando líneas) el conjunto de imágenes a utilizar y las etapas del algoritmo.
3. Ejecutar `gui.m`.



*¿Adónde vas?*

*Soy porque otros fueron.  
Porque soy, otros serán.*

*No soy, entonces, si no somos.  
¿Adónde ir?*

*¿Cuándo girar?  
Todo camino crea huella.  
Gran responsabilidad.  
Gran.*

*En calma estoy, atormentado.  
El tiempo, despiadado, no va a frenar.*

*Sigo.*

*Allá voy, y conmigo, otros vienen.*

*Voy.*

*Vamos.*

*Van.*